Universidad de Buenos Aires
Facultad de Ciencias Exactas y Naturales
Departamento de Computación

Morphing Tímbrico Mediante Interpolación de Pesos de Modelos VAE

Tesis de Licenciatura en Ciencias de la Computación

Facundo González Barnator

Director: Pablo Riera

Codirector: -

Buenos Aires, 2026

MORPHING TÍMBRICO MEDIANTE INTERPOLACIÓN DE PESOS DE MODELOS VAE

El *morphing tímbrico*— la generación de timbres intermedios entre instrumentos conocidos— es una herramienta de interés para la producción musical y el diseño sonoro, ya que permite expandir la paleta sonora más allá de los instrumentos acústicos existentes. Las técnicas usuales operan en el espacio latente de un único modelo generativo entrenado sobre múltiples instrumentos, lo que limita la fidelidad de cada timbre individual.

En este trabajo se propone un enfoque alternativo: entrenar autoencoders variacionales (β-VAE) especializados por instrumento a partir de un modelo base común, y generar timbres híbridos mediante la interpolación de los pesos de esos modelos.

El sistema se entrena sobre espectrogramas de magnitud obtenidos por STFT de cuatro instrumentos (piano, guitarra, voz y bajo) y se evalúa mediante Fréchet Audio Distance (FAD), similitud coseno sobre *embeddings* MERT, análisis del espacio latente con UMAP y error de reconstrucción.

Palabras claves: morphing tímbrico, autoencoder variacional, β-VAE, interpolación de pesos, síntesis de audio, Fréchet Audio Distance.

Índice general

1.. Introducción 1
- 1.1. Motivación 1
- 1.2. Antecedentes 1
- 1.3. Propuesta 1
- 1.4. Objetivos 1
- 1.5. Organización del trabajo 1

2.. Metodología 2
- 2.1. Datos y preprocesamiento 2
- 2.2. Arquitectura del modelo VAE 2
- 2.3. Estrategia de entrenamiento 2
- 2.4. Interpolación de pesos 2
- 2.5. Reconstrucción de audio 2
- 2.6. Métricas de evaluación 2
- 2.7. Aplicación interactiva 2

3.. Experimentación y resultados 3
- 3.1. Arquitectura del modelo y Experimentación β-VAE 3
- 3.2. Análisis del Espacio Latente 5
- 3.3. Interpolación 6
- 3.4. Barrido de dimensión del espacio latente 9
- 3.5. Variación de β 9
- 3.6. Análisis del espacio latente con UMAP 9
- 3.7. Interpolación entre pares de instrumentos 9
- 3.8. Audio morphing 9

4.. Conclusiones 10
- 4.1. Resumen de resultados 10
- 4.2. Contribuciones 10
- 4.3. Limitaciones 10
- 4.4. Trabajo futuro 10

1. INTRODUCCIÓN

1.1. Motivación

El timbre es el atributo perceptual que permite distinguir dos sonidos de igual altura y volumen producidos por fuentes distintas. La generación de timbres intermedios entre instrumentos conocidos, comúnmente denominada *morphing tímbrico*, resulta de particular interés tanto en la producción musical como en el diseño sonoro.

1.2. Antecedentes

Los autoencoders variacionales (VAE) fueron introducidos por Kingma y Welling [4] como un marco generativo que aprende representaciones latentes continuas mediante una distribución probabilística regularizada por la divergencia de Kullback-Leibler. Higgins et al. [3] propusieron el β-VAE, que pondera el término KL con un hiperparámetro β para controlar el balance entre calidad de reconstrucción y regularización del espacio latente.

En el modelado de sonido musical, Roche et al. [6] realizaron un estudio comparativo de distintas arquitecturas de autoencoders aplicadas a espectrogramas, mostrando que los modelos variacionales logran un buen compromiso entre reconstrucción y regularización del espacio latente. Caillon y Esling [1] demostraron con RAVE que los VAE pueden sintetizar audio de alta calidad en tiempo real. Riera, Eguía y Zabaljáuregui [5] exploraron la construcción de espacios de timbre mediante autoencoders dispersos, mostrando que las representaciones aprendidas capturan relaciones perceptuales entre timbres instrumentales.

Para la evaluación de audio generado se utiliza la Fréchet Audio Distance (FAD) [2], que cuantifica la distancia entre distribuciones de audio generado y de referencia a partir de *embeddings* neuronales.

1.3. Propuesta

1.4. Objetivos

1.5. Organización del trabajo

2. METODOLOGÍA

2.1. Datos y preprocesamiento

2.2. Arquitectura del modelo VAE

2.3. Estrategia de entrenamiento

2.4. Interpolación de pesos

2.5. Reconstrucción de audio

2.6. Métricas de evaluación

2.7. Aplicación interactiva

3. EXPERIMENTACIÓN Y RESULTADOS

3.1. Arquitectura del modelo y Experimentación β-VAE

Uno de los aspectos claves a definir en la arquitectura de los modelos es el tamaño del espacio latente. Como vimos antes, esperamos que a mayor tamaño del espacio latente mejores resultados de error de reconstrucción tendremos; sin embargo para el uso práctico de estos modelos lo ideal es mantener un tamaño acotado para poder generar representaciones fáciles de manipular. Si pensamos en una implementación de perillas para poder modificar el espacio latente, tener 4 perillas suena coherente para usar, pero tener 32 perillas puede resultar poco intuitivo.

En busca de encontrar el tamaño ideal experimentamos con los tamaños $2, 3, 4, 6, 8$ y graficamos el error de reconstrucción en el dataset de validación para cada modelo (instrumentos y modelo base). Esperamos verificar que el error disminuya a medida que el espacio latente aumenta, y queremos ver si podemos evitar ir hasta un espacio de dimensión 8 para tener una performance aceptable.

Fig. 3.1: Error de Reconstrucción (MSE) vs Dimensión de espacio latente, $\beta = 0$

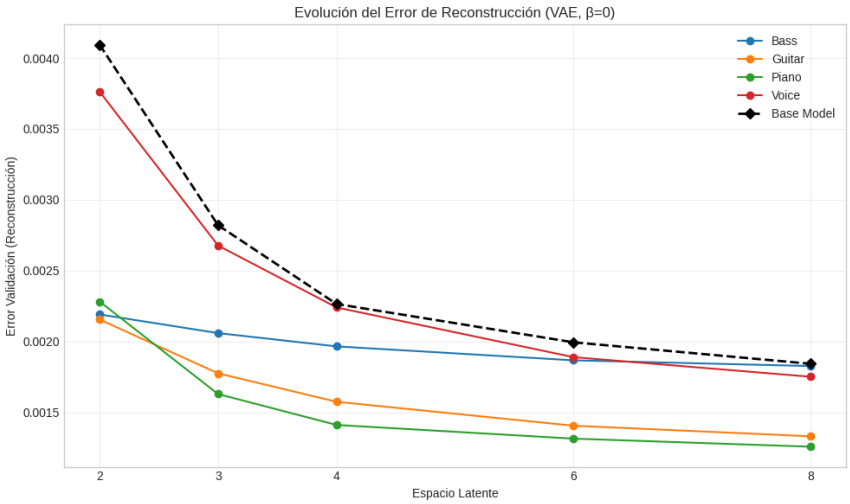

Analizando los resultados obtenidos en las figuras 3.1 3.2 podemos ver que con un espacio latente de dimensión 4 obtenemos una ganancia significativa en comparación a 2 y 3, y aumentar el tamaño a 6 y 8 no obteiene una ganancia significativa en general.

Nos interesa también verificar este comportamiento para la arquitectura $\beta - VAE$, esperando ver en magnitud un error de reconstrucción mayor (recordamos que la *loss* de estos modelos también está dada por la divergencia KL) pero con la misma tendencia.

Fig. 3.2: Error de Reconstrucción promedio general

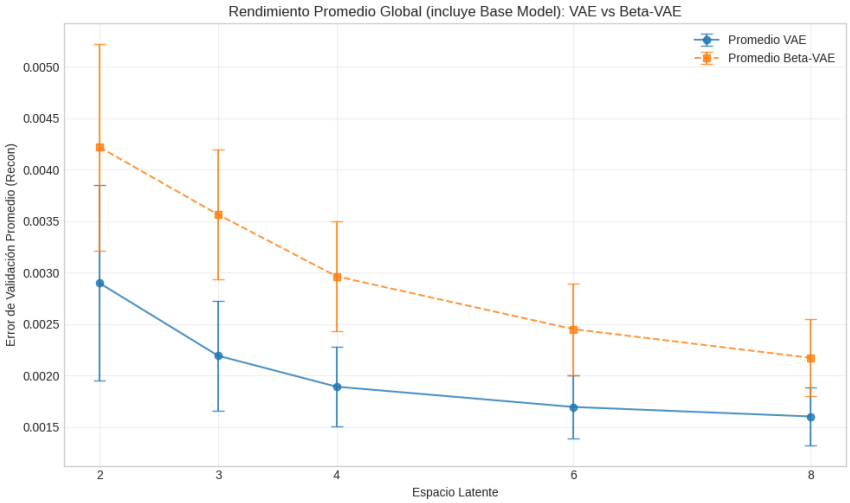

En efecto, lo observado para los modelos AE (con $\beta = 0$) se cumple cuando tenemos el beta activado. Debemos también verificar el comportamiento de la divergencia KL en los modelos $\beta - VAE$ con los diferentes tamaños de espacio latente.

Fig. 3.3: Divergencia KL vs Dimensión de espacio latente, $\beta = 0{,}001$

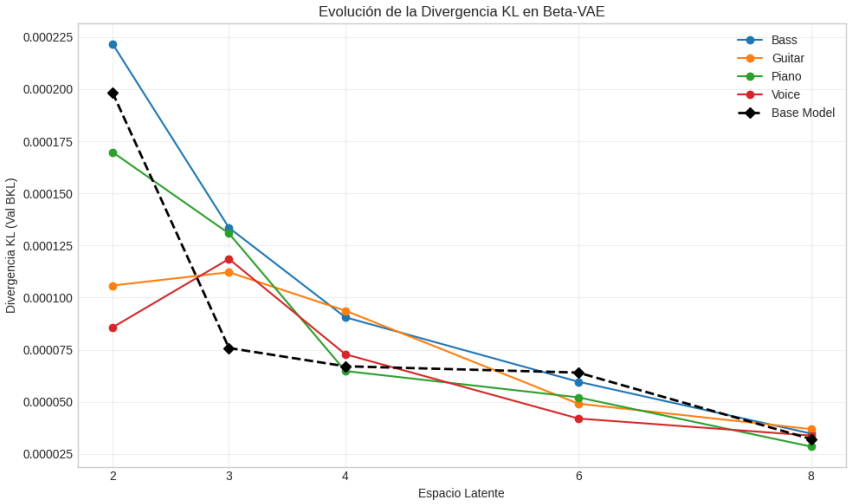

Efectivamente el salto más significativo se encuentra entre 2 y 4 y luego sigue mejorando pero con menos ganancia relativa. En base a estos resultados tomamos para el resto de experimentos arquitecturas con espacio latente de dimensión 4.

Fig. 3.4: Desglose: Error de Reconstrucción (MSE) por modelo

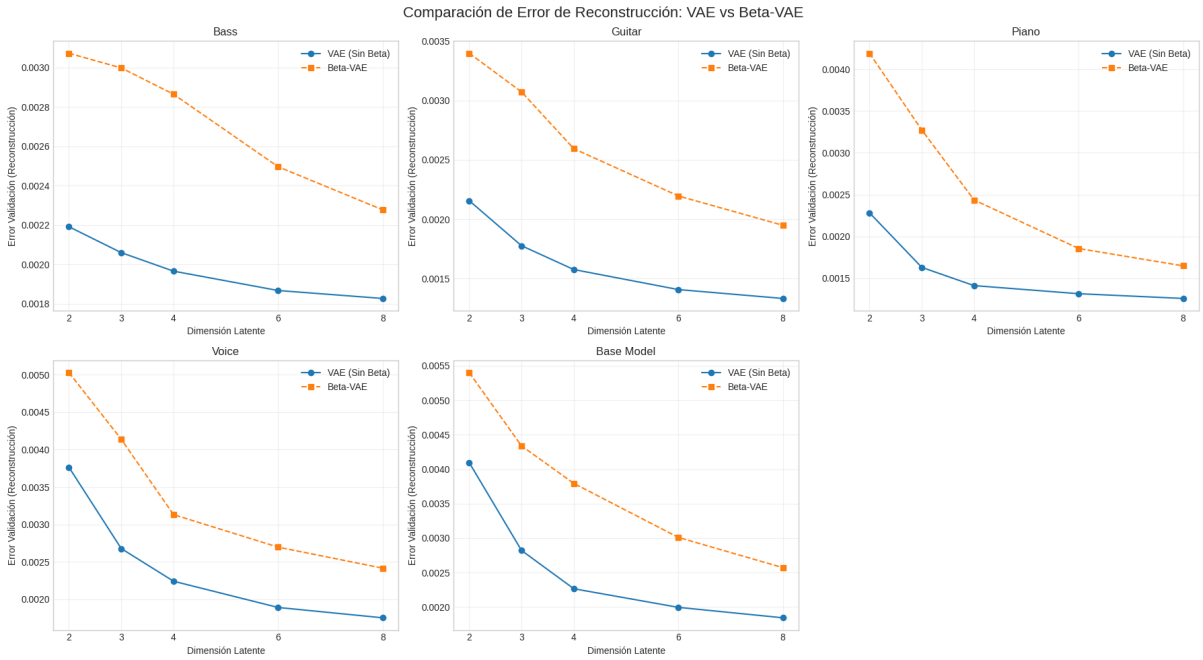

3.2. Análisis del Espacio Latente

Fig. 3.5: Proyección a 2 dimensiones utilizando UMAP.

(a) $\beta = 0{,}001$. *(b)* $\beta = 0$.

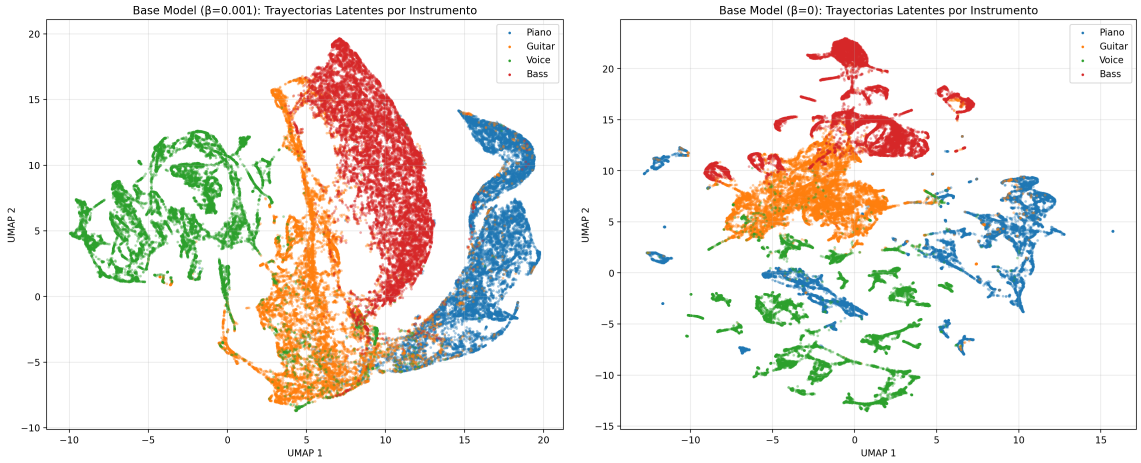

Fig. 3.6: Distancia entre clusters de la proyección REVISAR.

(a) $\beta = 0{,}001$. (b) $\beta = 0$.

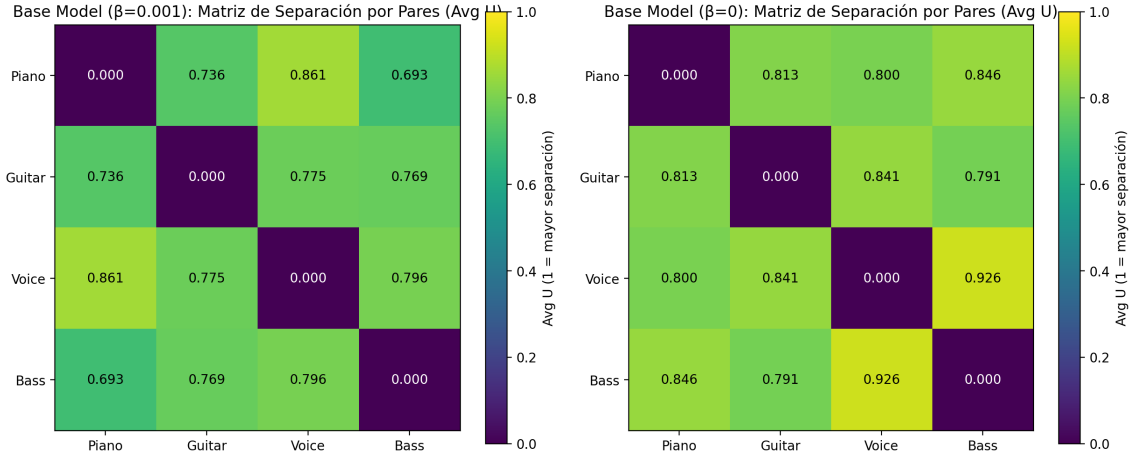

3.3. Interpolación

El primer experimento de interpolación tiene como objetivo verificar que la transición del parámetro α de 0 a 1 aproxima gradualmente las características del audio generado a las del instrumento de destino (Instrumento B). Para ello, se fijó el Instrumento B (en este caso, piano), se muestreó un vector latente aleatorio Z y se decodificó utilizando el modelo correspondiente a dicho instrumento, estableciendo así un audio de referencia. Posteriormente, para distintos valores intermedios de α, se interpolaron los pesos de los modelos A y B, se decodificó el mismo vector Z y se evaluó la similitud respecto a la referencia utilizando dos métricas: distancia coseno sobre *embeddings* de BERT y FAD (*Fréchet Audio Distance*). Trivialmente, cuando $\alpha = 1$, la similitud debe alcanzar su valor máximo en ambos casos. La hipótesis principal es que la curva de similitud crecerá de forma monotónica en función de α, evidenciando una transición acústica hacia el timbre del piano.

Este procedimiento se evaluó bajo dos configuraciones de entrenamiento: modelos inicializados desde un *checkpoint* común con un factor de regularización $\beta = 0{,}001$, y modelos entrenados desde cero (*scratch*) con $\beta = 0$. Se espera observar un contraste significativo en la dinámica de interpolación. Partir de modelos con *checkpoint* compartido y $\beta > 0$ debería resultar en una curva más suave y predecible a medida que α aumenta, dado que la interpolación directa de pesos es más efectiva cuando los modelos habitan el mismo entorno en el espacio de parámetros. Por el contrario, al interpolar modelos entrenados desde *scratch* y sin regularización, es probable que los valores intermedios de α generen representaciones ruidosas, impidiendo un crecimiento gradual de la similitud y resultando en un salto abrupto únicamente para valores de α muy cercanos a 1.

Para garantizar la robustez de los resultados, este proceso se repitió utilizando 10 vectores latentes aleatorios diferentes. En los gráficos subsiguientes se reporta el promedio de las métricas de similitud evaluadas, junto con su desviación estándar, para cada valor de α.

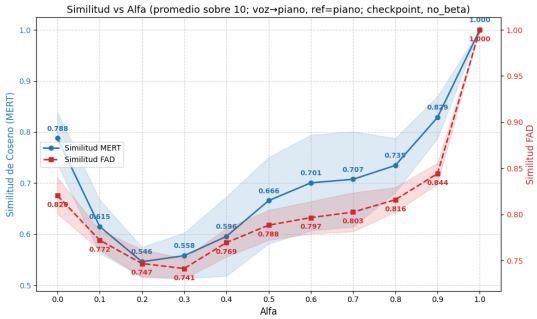

Fig. 3.7: Similitud en función de α, entrenado desde *checkpoint*, $\beta = 0$

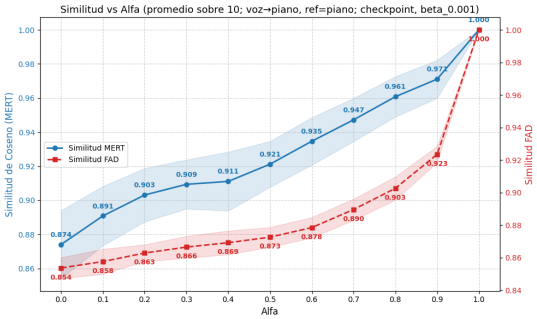

Fig. 3.8: Similitud en función de α, entrenado desde *checkpoint*, $\beta = 0{,}001$

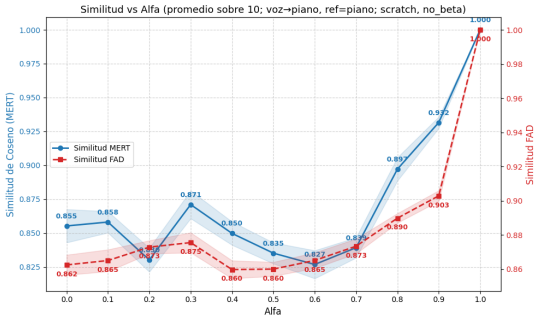

Fig. 3.9: Similitud en función de α, entrenado desde *scratch*, $\beta = 0$

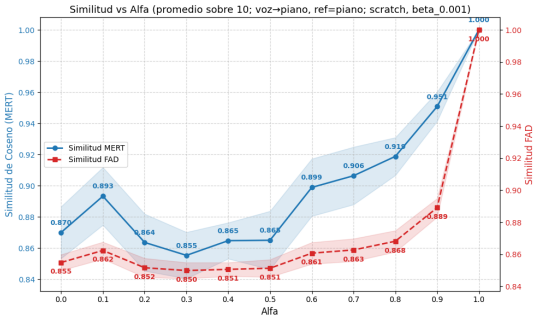

Fig. 3.10: Similitud en función de α, entrenado desde *scratch*, $\beta = 0{,}001$

En la figura 3.8 se puede observar, en ambas métricas, un crecimiento suave y que aumenta consistentemente en cada α, mientras que para el caso de modelos entrenados desde *scratch* y sin beta 3.9 no hay una mejora entre $\alpha = 0$ y $\alpha = 0{,}7$. Luego para $\alpha \in [0{,}8, 1{,}0]$ se observa una crecida pronunciada dado que ya estamos en un punto de la interpolación donde casi todo el modelo es el correspondiente al instrumento B.

Esta observación nos da un indicio de lo que creíamos: interpolar modelos que fueron entrenados desde *scratch* y sin beta ($\beta = 0$) nos lleva a peores interpolaciones.

Con esto verificamos que acercarnos en alfa a un extremo efectivamente acerca el sonido al instrumento que corresponde. Nos interesa verificar también que dicha interpolación se fue alejando del instrumento A y que no se acerca en promedio a otros instrumentos.

Para esto, se propone un experimento similar en el que se medirá la similitud contra un audio de referencia del instrumento A y un audio de referencia de un instrumento *witness* diferente de A y B. Lo que esperamos que suceda a medida que crece el α es que se debe acercar en similitud al instrumento B, mientras que se debe alejar del instrumento A. Con respecto al instrumento *witness*, se debe mantener en un valor constante a lo largo de los distintos valores de alpha. También esperamos que la curva de la similitud del instrumento A y la curva de la similitud del instrumento B se crucen en aproximadamente $\alpha = 0{,}5$.

Vamos a comparar las distintas configuraciones de modelos entrenados desde *checkpoint* y *scratch* combinado con los valores de $\beta = 0$ y $\beta = 0{,}001$. Usando como instrumento A piano, instrumento B guitarra e instrumento *witness* voz.

Fig. 3.11: Transición de Piano a Guitarra; comparación entre origen y β

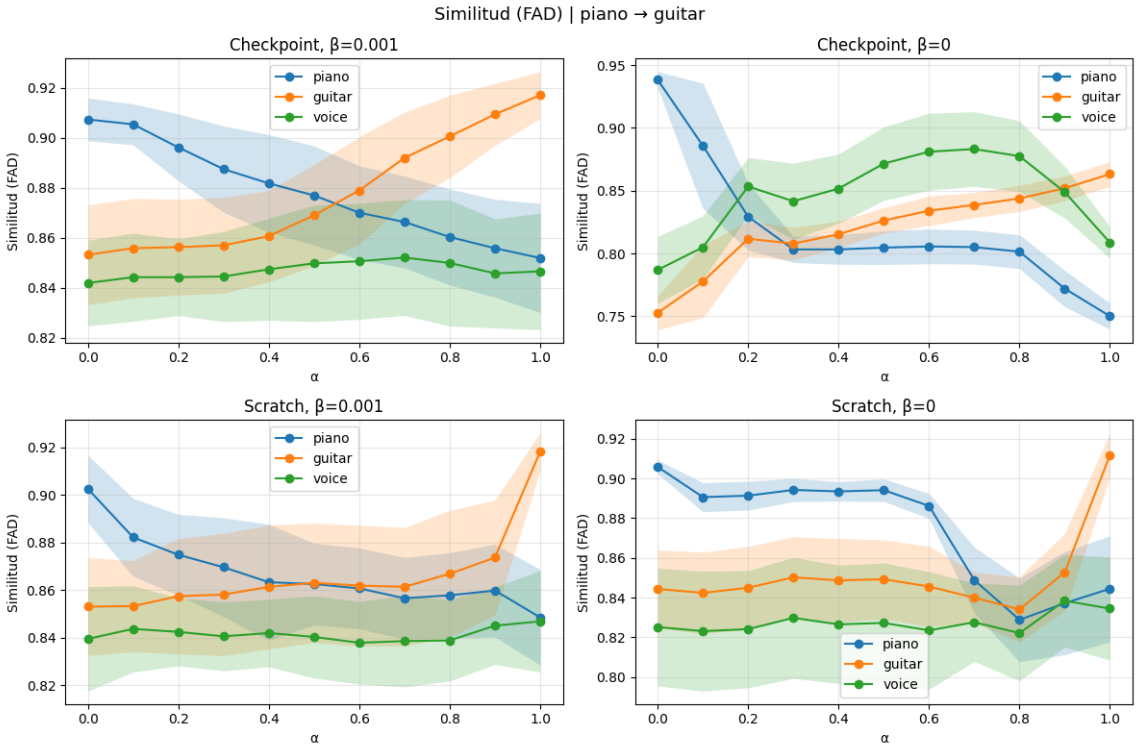

Como esperabamos, la configuración que mejor se comporta es la de modelos entrenados desde *checkpoint* y $\beta = 0{,}001$; donde se puede observar que el instrumento A (piano) decrece consistenmente a la vez que el instrumento B (guitarra) crece, cruzándose en $\alpha = 0{,}5$. En este caso, la voz se mentiene con una similitud constante.

Luego, para los casos de *scratch* el comportamiento es menos predecible: en el caso de $\beta = 0{,}001$ pudimos observar una leve transferencia tímbrica pero no muy consistente ya que en los alfas intermedios no hay mucha variación mientras que para el caso de $\beta = 0$ directamente no hay transferencia y la similitud del instrumento B recién aumenta a partir de $\alpha = 0{,}8$.

El caso de *checkpoint* y $\beta = 0$ sí tuvo la transferencia tímbrica que buscamos pero de una manera más brusca, ya que se observa una caída pronunciada del instrumento A en los primeros valores de alfa. También en este caso el instrumento testigo tuvo un comportamiento más errático.

Logramos con este experimento confirmar que la configuración de modelos más adecuada para la interpolación es la de modelos entrenados desde *checkpoint* y con un $\beta > 0$, en particular $\beta = 0{,}001$.

3.4. Barrido de dimensión del espacio latente

3.5. Variación de β

3.6. Análisis del espacio latente con UMAP

3.7. Interpolación entre pares de instrumentos

3.8. Audio morphing

4. CONCLUSIONES

4.1. Resumen de resultados

4.2. Contribuciones

4.3. Limitaciones

4.4. Trabajo futuro

Bibliografía

[1] Caillon, A., and Esling, P. Rave: A variational autoencoder for fast and high-quality neural audio synthesis. *arXiv preprint arXiv:2111.05011* (2021).

[2] Gui, A., Gamper, H., Braun, S., and Emmanouilidou, D. Adapting frechet audio distance for generative music evaluation, 2024.

[3] Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., Mohamed, S., and Lerchner, A. beta-vae: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations (ICLR)* (2017).

[4] Kingma, D. P., and Welling, M. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114* (2013).

[5] Riera, P. E., Eguía, M. C., and Zabaljáuregui, M. Timbre spaces with sparse autoencoders. In *16th Brazilian Symposium on Computer Music (SBCM)* (2017).

[6] Roche, F., Hueber, T., Limier, S., and Girin, L. Autoencoders for music sound modeling: a comparison of linear, shallow, deep, recurrent and variational models, 2019.