



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES
DEPARTAMENTO DE COMPUTACIÓN

Morphing Tímbrico Mediante Interpolación de Pesos de Modelos VAE

Tesis de Licenciatura en Ciencias de la Computación

Facundo González Barnator

Director: Pablo Riera

Codirector: -

Buenos Aires, 2026

MORPHING TÍMBRICO MEDIANTE INTERPOLACIÓN DE PESOS DE MODELOS VAE

El *morphing tímbrico*— la generación de timbres intermedios entre instrumentos conocidos— es una herramienta de interés para la producción musical y el diseño sonoro, ya que permite expandir la paleta sonora más allá de los instrumentos acústicos existentes. Las técnicas usuales operan en el espacio latente de un único modelo generativo entrenado sobre múltiples instrumentos, lo que limita la fidelidad de cada timbre individual.

En este trabajo se propone un enfoque alternativo: entrenar autoencoders variacionales (β -VAE) especializados por instrumento a partir de un modelo base común, y generar timbres híbridos mediante la interpolación de los pesos de esos modelos.

El sistema se entrena sobre espectrogramas de magnitud obtenidos por STFT de cuatro instrumentos (piano, guitarra, voz y bajo) y se evalúa mediante Fréchet Audio Distance (FAD), similitud coseno sobre *embeddings* MERT, análisis del espacio latente con UMAP y error de reconstrucción.

Palabras claves: morphing tímbrico, autoencoder variacional, β -VAE, interpolación de pesos, síntesis de audio, Fréchet Audio Distance.

Índice general

1..	Introducción	1
1.1.	Motivación	1
1.2.	Antecedentes	1
1.3.	Propuesta	2
2..	Metodología	3
2.1.	Dataset	3
2.2.	Arquitectura del modelo VAE	4
2.3.	Estrategia de entrenamiento	4
2.4.	Interpolación de pesos	4
2.5.	Reconstrucción de audio	4
2.6.	Métricas de evaluación	4
2.7.	Aplicación interactiva	4
3..	Experimentación y resultados	5
3.1.	Arquitectura del modelo y Experimentación β -VAE	5
3.2.	Selección del parámetro β	7
3.3.	Análisis del Espacio Latente	8
3.4.	Interpolación	10
3.4.1.	Elección de Métricas de Similitud	10
3.4.2.	Experimentos de Interpolación	12
4..	Conclusiones	16
4.1.	Resumen de resultados	16
4.2.	Contribuciones	16
4.3.	Limitaciones	16
4.4.	Trabajo futuro	16

1. INTRODUCCIÓN

1.1. Motivación

El timbre es el atributo perceptual que permite distinguir dos sonidos de igual altura y volumen producidos por fuentes distintas— por ejemplo, una misma nota ejecutada en un piano y en una guitarra. La capacidad de generar timbres intermedios entre instrumentos conocidos, comúnmente denominada *morphing* tímbrico, cobra especial relevancia tanto en la producción musical como en el diseño sonoro, dado que permite expandir la paleta acústica más allá de las limitaciones de los instrumentos acústicos tradicionales.

Con el propósito de proveer herramientas para la síntesis de nuevas sonoridades a partir de timbres familiares, resulta de gran interés explorar el potencial generativo de modelos basados en redes neuronales profundas. En particular, este trabajo se enfoca en investigar la factibilidad y eficacia de realizar procesos de interpolación que operen directamente sobre las representaciones tímbricas aprendidas de distintos instrumentos.

1.2. Antecedentes

Los autoencoders variacionales (VAE), introducidos por Kingma y Welling [4], constituyen un marco generativo consolidado que aprende representaciones latentes continuas a partir de los datos de entrada. A diferencia de los autoencoders clásicos, el enfoque variacional impone una distribución probabilística sobre el espacio latente mediante la divergencia de Kullback-Leibler (KL). Esto no solo facilita la generación de nuevas muestras, sino que además habilita la interpolación entre ellas. Higgins et al. [3] propusieron el β -VAE, una variante que pondera el término de la divergencia KL mediante un hiperparámetro β . Este factor permite regular el balance entre la calidad de la reconstrucción y la regularización del espacio latente, favoreciendo la emergencia de representaciones más estructuradas cuando $\beta > 0$.

En el ámbito de la síntesis y el modelado de audio musical, Roche et al. [7] realizaron un estudio comparativo de diversas arquitecturas de autoencoders—incluyendo configuraciones lineales, superficiales, profundas, recurrentes y variacionales— aplicadas a la representación de espectrogramas de instrumentos musicales. Sus conclusiones demostraron que los modelos variacionales logran el mejor compromiso entre fidelidad de reconstrucción y regularización del espacio latente, sentando un precedente directo para la aplicación de los VAE en el modelado tímbrico.

Posteriormente, orientados al procesamiento en el dominio del audio, Caillon y Esling [1] demostraron con la arquitectura RAVE que los VAE son capaces de sintetizar audio de alta calidad en tiempo real operando directamente sobre la forma de onda cruda. Por su parte, Riera, Eguía y Zabaljáuregui [5] exploraron la construcción de espacios tímbricos mediante autoencoders dispersos (*sparse autoencoders*), evidenciando que las representaciones aprendidas capturan las relaciones perceptuales entre timbres instrumentales de manera consistente con la percepción humana.

1.3. Propuesta

Si bien los antecedentes reseñados demuestran la utilidad de los modelos generativos para representar el timbre, la síntesis de sonoridades intermedias entre instrumentos específicos permanece como un problema abierto. Las técnicas convencionales de interpolación suelen operar dentro del espacio latente de un único modelo entrenado conjuntamente sobre múltiples instrumentos, una estrategia que frecuentemente limita la fidelidad y el detalle de cada timbre individual.

En este trabajo proponemos un enfoque alternativo: entrenar modelos VAE especializados de forma independiente para cada instrumento y, posteriormente, realizar una interpolación en el espacio de sus pesos o parámetros. De este modo, se generan modelos intermedios cuyos *decoders* producen timbres híbridos. Esta estrategia opera directamente sobre la parametrización del modelo en lugar de hacerlo sobre el espacio latente, buscando preservar la capacidad reconstructiva y la riqueza espectral de cada modelo especializado.

El sistema propuesto trabaja con espectrogramas de magnitud obtenidos mediante la Transformada de Fourier de Tiempo Corto (STFT). Estas representaciones son proyectadas por el *encoder* del VAE hacia un espacio latente de baja dimensionalidad (típicamente de 4 dimensiones) y luego reconstruidas por el *decoder*. Para evaluar cuantitativamente la calidad de las interpolaciones resultantes, se utiliza la métrica Fréchet Audio Distance (FAD) [2] combinada con *embeddings* extraídos del modelo MERT. Esto permite medir con rigor la distancia perceptual entre las distribuciones del audio generado y el de referencia.

2. METODOLOGÍA

2.1. Dataset

Como parte fundamental de este trabajo, necesitamos definir el dataset con el que vamos a entrenar y luego validar los modelos. Para eso primero definimos el conjunto de instrumentos en los que vamos a trabajar: Piano, Guitarra, Bajo y Voz.

Para el caso de piano, se armó un dataset basado en interpretaciones de piezas de música clásica libres de derecho extraídas de internet.


En la guitarra se utilizó una sección del dataset GuitarSet [9], especializado en los fragmentos sólo de guitarra eléctrica, variando entre fragmentos solo melódicos y armónicos (rasgueos, acordes, etc.).

Para el bajo, se extrajo del dataset FiloBass [6] líneas de bajo y contra bajo de canciones conocidas (standards) de jazz.

Para la voz se aprovechó el dataset VocalSet [8] el cual provee mucho material de diferentes voces, escalas, melodías, etc. Se seleccionó un conjunto representativo que incluye 4 voces diferentes (2 hombre, 2 mujer) y pistas que representan melodías, escalas, arpeggios.

Para cada instrumento se recolectó un total de 87 minutos aproximadamente, lo que conforma un dataset suficiente para completar la tarea de entrenamiento y validación propuesta, y logra que el entrenamiento sea reproducible sin una necesidad de cómputo muy costosa.

2.2. Arquitectura del modelo VAE



2.3. Estrategia de entrenamiento

2.4. Interpolación de pesos

2.5. Reconstrucción de audio

2.6. Métricas de evaluación

2.7. Aplicación interactiva


3. EXPERIMENTACIÓN Y RESULTADOS

3.1. Arquitectura del modelo y Experimentación β -VAE

Uno de los aspectos clave a definir en la arquitectura de los modelos es el tamaño del espacio latente. Como cabe esperar, a mayor dimensión del espacio latente menor es el error de reconstrucción; sin embargo, para el uso práctico de estos modelos resulta deseable mantener un tamaño acotado, de modo que las representaciones sean fáciles de manipular. Si pensamos en una implementación basada en perillas para modificar el espacio latente, contar con 4 perillas resulta coherente, mientras que tener 32 puede resultar poco intuitivo.

Con el objetivo de encontrar el tamaño ideal, experimentamos con dimensiones 2, 3, 4, 6 y 8, y graficamos el error de reconstrucción sobre el conjunto de validación para cada modelo (los modelos por instrumento y el modelo base). El propósito es verificar que el error disminuya a medida que la dimensión del espacio latente aumenta y, a la vez, evaluar si es posible evitar dimensiones tan grandes como 8 manteniendo una performance aceptable.


Fig. 3.1: Error de Reconstrucción (MSE) vs Dimensión de espacio latente, $\beta = 0$



Analizando los resultados de las figuras 3.1 y 3.2 observamos que, con un espacio latente de dimensión 4, obtenemos una ganancia significativa respecto a las dimensiones 2 y 3, mientras que aumentar el tamaño a 6 u 8 no aporta una mejora relevante.


Nos interesa también verificar este comportamiento para la arquitectura β -VAE, donde esperamos observar un error de reconstrucción mayor en magnitud—ya que la *loss* de estos modelos incorpora también la divergencia KL—pero con la misma tendencia.

Fig. 3.2: Error de Reconstrucción (MSE) promedio sobre todos los instrumentos vs. dimensión del espacio latente, con desvío estándar.




En efecto, lo observado para los modelos AE (con $\beta = 0$) se cumple también con β activado. Resta verificar el comportamiento de la divergencia KL en los modelos β -VAE para los distintos tamaños de espacio latente, presentado en la figura 3.3.

Fig. 3.3: Divergencia KL vs Dimensión de espacio latente, $\beta = 0,001$




Efectivamente, el salto más significativo se encuentra entre las dimensiones 2 y 4, y a partir de allí la KL sigue disminuyendo pero con una ganancia relativa menor. En la figura 3.4 se presenta además el desglose del error de reconstrucción por instrumento, que confirma la misma tendencia. En base a estos resultados, adoptamos para el resto de los experimentos arquitecturas con espacio latente de dimensión 4.

Fig. 3.4: Desglose: Error de Reconstrucción (MSE) por modelo



3.2. Selección del parámetro β

Definida la dimensión del espacio latente, resta fijar el valor del coeficiente β que pondera el término de divergencia KL en la *loss*. Para ello entrenamos el modelo base con cinco valores de β — 0,01, 0,001, 0,0001, 10^{-5} y 0— y analizamos cómo varían el error de reconstrucción y la divergencia KL sobre el conjunto de validación. La figura 3.5 presenta la evolución suavizada de ambas métricas a lo largo del entrenamiento.

Fig. 3.5: Evolución suavizada (media móvil) del error de reconstrucción (izquierda) y de la divergencia KL (derecha) sobre validación, para los cinco valores de β .


El comportamiento observado responde a la tensión intrínseca del β -VAE: a medida que β disminuye, el error de reconstrucción se reduce, pero la divergencia KL crece— es decir, el espacio latente queda menos regularizado—. Los casos extremos ilustran ambos

límites: con $\beta = 0,01$ la regularización es tan fuerte que penaliza marcadamente la reconstrucción (error en torno a 0,008), mientras que con $\beta = 0$ la KL crece sin control, dado que ningún término acota la distribución latente. Existe entonces un compromiso entre fidelidad de reconstrucción y regularización del espacio latente que ningún valor optimiza simultáneamente.


Para identificar el mejor balance planteamos este compromiso como una curva de Pareto, ubicando cada modelo según su error de reconstrucción y su divergencia KL promedio en la etapa final del entrenamiento. La figura 3.6 muestra esta curva en escala lineal—excluyendo $\beta = 0$ por tener una KL desproporcionadamente alta— y en escala logarítmica incluyéndolo.

Fig. 3.6: Compromiso entre error de reconstrucción y divergencia KL para los distintos valores de β .

(a) Escala lineal (excluyendo $\beta = 0$).



(b) Escala logarítmica (incluyendo $\beta = 0$).




El valor $\beta = 0,001$ se ubica precisamente en el codo de la curva de Pareto: representa el punto a partir del cual seguir reduciendo β aporta una mejora marginal en la reconstrucción a costa de un incremento sustancial de la divergencia KL, mientras que aumentarlo hacia 0,01 degrada la reconstrucción sin un beneficio proporcional en la regularización. En otras palabras, es el valor que mejor equilibra ambos objetivos.

Esta elección numérica fue contrastada además con una evaluación subjetiva: al escuchar los audios reconstruidos por los modelos entrenados con cada β , los obtenidos con $\beta = 0,001$ ofrecen una calidad perceptual comparable a la de los valores más bajos, sin la degradación audible que introduce $\beta = 0,01$. En base a este doble criterio—cuantitativo y perceptual—adoptamos $\beta = 0,001$ como configuración del β -VAE para el resto del trabajo, conservando además la variante $\beta = 0$ (AE estándar) como línea de base para las comparaciones posteriores.

3.3. Análisis del Espacio Latente


Para analizar la organización del espacio latente del modelo base, proyectamos los *embeddings* a 2 dimensiones mediante UMAP, etiquetando cada muestra con el instrumento al que corresponde. Esto nos permite evaluar visualmente si los distintos instrumentos forman *clusters* diferenciados y comparar el comportamiento entre las configuraciones $\beta = 0$ y $\beta = 0,001$. Los resultados se presentan en la figura 3.7.

Fig. 3.7: Proyección a 2 dimensiones del espacio latente del modelo base utilizando UMAP.



En ambas configuraciones se observa una separación clara entre los distintos instrumentos, que forman *clusters* diferenciados. La diferencia más notoria es que el modelo con $\beta = 0,001$ presenta una nube de puntos visiblemente más suavizada y compacta, consistente con el efecto regularizador que la divergencia KL impone sobre el espacio latente; el modelo con $\beta = 0$, en cambio, dispone los *clusters* de forma más dispersa.

Para cuantificar esta separación de manera objetiva utilizamos el estadístico U de Wilcoxon-Mann-Whitney en su versión multidimensional, calculado sobre los vectores latentes de cada par de instrumentos. La métrica se normaliza al intervalo $[0, 1]$, donde un valor cercano a 1 indica que ambas distribuciones están fuertemente separadas en el espacio latente y un valor cercano a 0,5 indica solapamiento total. Los resultados se sintetizan en la matriz de la figura 3.8.

Fig. 3.8: Matriz de separación entre instrumentos en el espacio latente del modelo base, medida con el estadístico U de Wilcoxon-Mann-Whitney multidimensional (valores cercanos a 1 indican mayor separación).

La matriz confirma cuantitativamente lo que sugiere la visualización: ambos enfoques logran una separación clara entre instrumentos, con valores de U próximos a 1 en todos los pares. Resulta interesante que el modelo sin regularización ($\beta = 0$) alcanza incluso una separación algo mayor— con un máximo de 0,926 para el par bajo-voz—, lo cual es coherente con un espacio latente más disperso. Sin embargo, esta mayor separación no es necesariamente deseable para nuestro objetivo: un espacio latente menos regularizado tiende a perjudicar las interpolaciones, ya que la falta de suavidad dificulta las transiciones graduales entre instrumentos. Esta hipótesis será puesta a prueba en la sección siguiente.

3.4. Interpolación

Esta sección se centra en la interpolación de pesos entre dos modelos especializados en instrumentos distintos. Tal como se definió en la sección de metodología, generaremos un modelo intermedio en función de tres parámetros: un modelo origen A, un modelo destino B y un coeficiente de interpolación $\alpha \in [0, 1]$. De este modo, con $\alpha = 0$ obtenemos exactamente el modelo A, y con $\alpha = 1$ obtenemos el modelo B.

El objetivo principal de esta interpolación es lograr una transferencia tímbrica suave entre ambos modelos. Por ejemplo, si establecemos un modelo de voz como modelo A y un modelo de piano como modelo B, el comportamiento esperado es que, a medida que α se incrementa de 0 a 1, el audio sintetizado adquiera progresivamente características tímbricas más cercanas a las del piano.

A lo largo de los experimentos, analizaremos el impacto de las distintas configuraciones de entrenamiento introducidas previamente. Para mantener la consistencia, clasificaremos los modelos según su inicialización: desde cero (*Scratch*) o desde un modelo base pre-entrenado (*Checkpoint*); y según su regularización en el espacio latente: Autoencoder estándar (AE, con $\beta = 0$) o β -VAE (con $\beta = 0,001$).


3.4.1. Elección de Métricas de Similitud

Para evaluar empíricamente la interpolación, resulta indispensable definir una métrica que cuantifique la similitud tímbrica entre la salida de los modelos y los audios de referencia. En este trabajo, comparamos el desempeño de dos enfoques: la similitud coseno entre embeddings extraídos con MERT, y la Distancia de Fréchet para Audio (FAD, por sus siglas en inglés) [2], la cual es altamente citada en la literatura sobre el tema.

La principal diferencia teórica entre ambas recae en que FAD considera la varianza de las distribuciones, lo que a priori mejoraría su precisión al evaluar fragmentos de audio de mayor duración. Sin embargo, en instantes de audio cortos (pocos frames de sonido constante) donde prima el análisis tímbrico, ambas métricas deberían ofrecer resultados comparables.


Para validar esto empíricamente, evaluamos la interpolación de voz a piano utilizando como referencia el audio reconstruido por el modelo de piano. Analizamos dos escenarios de entrada para el decoder: partiendo de un vector latente Z aleatorio fijo, y partiendo de un vector latente Z proveniente de codificar un fragmento de audio de validación. Comparamos los resultados utilizando dos configuraciones extremas: *Scratch-AE* ($\beta = 0$) y *Checkpoint- β -VAE* ($\beta = 0,001$).

Fig. 3.9: Comparación de métricas (Similitud Coseno vs. FAD) partiendo de un vector latente Z aleatorio.



Los resultados presentados en la Figura 3.9 ilustran el comportamiento partiendo de un Z aleatorio. Para la configuración *Scratch-AE*, es esperable que no haya una transición suave (ya que interpolamos espacios latentes disjuntos y sin regularizar); no obstante, se observa que la similitud coseno presenta picos y fluctuaciones erráticas, mientras que FAD se mantiene notablemente más estable. Por el contrario, en la configuración *Checkpoint- β -VAE*, ambas métricas muestran el crecimiento suave y sostenido esperado, presentando una alta correlación en este escenario estático.

Fig. 3.10: Comparación de métricas (Similitud Coseno vs. FAD) partiendo de un vector latente Z codificado desde un audio real.



Al evaluar con un vector latente Z proveniente de un audio real (Figura 3.10), las deficiencias de la similitud coseno se hacen más evidentes. En la configuración *Scratch-AE*, la similitud coseno sufre una alta variación y dispersión. FAD, en cambio, captura correctamente que el modelo no logra asimilarse al timbre destino hasta llegar a $\alpha \approx 0,95$.


En la configuración *Checkpoint- β -VAE*, FAD traza una curva de crecimiento predecible y suave con baja desviación estándar, confirmando que la interpolación es efectiva. La similitud coseno, aunque logra marcar la tendencia general de transferencia tímbrica, presenta caídas anómalas (e.g., en $\alpha = 0,20$) y mayor dispersión. Dado que FAD demostró ser más robusta y consistente frente a distintas entradas y configuraciones, nos basaremos

en ella para el resto de los experimentos de esta sección.



3.4.2. Experimentos de Interpolación

Habiendo validado la métrica, procedemos a verificar si la transferencia tímbrica hacia un instrumento de destino (piano) se sostiene independientemente del instrumento de origen (bajo, guitarra, voz). Evaluamos múltiples muestras de vectores Z para cada caso y graficamos el promedio de la similitud FAD junto con su dispersión.

Fig. 3.11: Comparación agregada entre configuraciones, interpolando desde múltiples instrumentos hacia piano.




Como se observa en la Figura 3.11, existe una transferencia tímbrica en todos los escenarios, pero las diferencias de rendimiento entre configuraciones son notables. La curva de mejor comportamiento corresponde a *Checkpoint- β -VAE* ($\beta = 0,001$), seguida por *Scratch- β -VAE*. Esto sugiere fuertemente que la regularización impuesta por $\beta > 0$ para suavizar el espacio latente es el factor de mayor impacto para lograr interpolaciones de alta calidad. Secundariamente, compartir un punto de partida común en los pesos del modelo (*Checkpoint*) aporta una mejora adicional frente a los modelos entrenados desde cero.

Fig. 3.12: Desglose por instrumento de origen para la configuración *Checkpoint- β -VAE* ($\beta = 0,001$).Fig. 3.13: Desglose por instrumento de origen para la configuración *Scratch-AE* ($\beta = 0$).

Al desglosar los resultados (Figuras 3.12 y 3.13), confirmamos que este patrón es consistente para cualquier instrumento de origen. Queda en evidencia que los modelos sin regularizar (*Scratch-AE*) fracasan en realizar una transición gradual, retrasando el cambio tímbrico hacia los valores extremos de α .

Para descartar que el comportamiento observado sea particular del piano como destino, repetimos el análisis tomando sucesivamente cada instrumento como destino y los tres restantes como origen. Promediando la similitud FAD sobre todas las combinaciones y muestras de Z , obtenemos la comparación agregada de la Figura 3.14.

Fig. 3.14: Comparación agregada entre configuraciones, interpolando desde múltiples instrumentos hacia todos los instrumentos.




El patrón se mantiene de forma consistente a lo largo de todas las combinaciones de instrumentos de origen y destino: la configuración *Checkpoint- β -VAE* es sistemáticamente la de mejor desempeño. Tanto incorporar únicamente la regularización ($\beta > 0$) como partir de un *checkpoint* común mejoran la similitud respecto del peor caso (*Scratch-AE*), lo que confirma que ambos factores contribuyen de manera independiente a la calidad de la interpolación, siendo la regularización del espacio latente el de mayor impacto.

Para dar el análisis por concluido, resta verificar una última condición: a medida que el audio sintetizado se aproxima tímbricamente al instrumento B, debe necesariamente alejarse de las características del instrumento A, y, fundamentalmente, no debe adoptar rasgos de otros instrumentos ajenos a la interpolación (un instrumento *testigo*).

Se espera que, a medida que α crezca, la similitud con el instrumento B aumente y la del instrumento A disminuya, cruzándose aproximadamente en $\alpha = 0,5$. Simultáneamente, la similitud con el instrumento testigo debería mantenerse constante. Para este experimento definimos piano como instrumento A, guitarra como instrumento B, y voz como instrumento testigo.

Fig. 3.15: Transición cruzada de piano a guitarra. Comparación entre orígenes (*Checkpoint* vs. *Scratch*) y regularización (β). La voz actúa como instrumento testigo.



Los resultados presentados en la Figura 3.15 corroboran nuestra hip tesis para la configuraci n *Checkpoint*- β -VAE. Se observa que la similitud con el piano decrece de manera consistente mientras la similitud con la guitarra aumenta, ocurriendo el punto de cruce alrededor de $\alpha = 0,5$, todo esto mientras la voz (instrumento testigo) se mantiene constante.

Por el contrario, los modelos entrenados desde *Scratch* exhiben un comportamiento indeseable. A n con $\beta = 0,001$, la transferencia es poco consistente para valores intermedios de α ; y con $\beta = 0$, la transici n es pr cticamente inexistente hasta $\alpha > 0,8$. El caso de *Checkpoint*-AE ($\beta = 0$) logra la transferencia deseada, pero de forma mucho m s abrupta, provocando adem s fluctuaciones err ticas en la curva del instrumento testigo.

En conclusi n, estos experimentos confirman emp ricamente que la arquitectura m s robusta para garantizar una transferencia t mbrica predecible, gradual e independiente en la interpolaci n de pesos es la basada en modelos con inicializaci n com n y espacios latentes regularizados (*Checkpoint* con $\beta = 0,001$).

4. CONCLUSIONES

- 4.1. Resumen de resultados**
- 4.2. Contribuciones**
- 4.3. Limitaciones**
- 4.4. Trabajo futuro**

Bibliografía

- [1] CAILLON, A., AND ESLING, P. Rave: A variational autoencoder for fast and high-quality neural audio synthesis. *arXiv preprint arXiv:2111.05011* (2021).
- [2] GUI, A., GAMPER, H., BRAUN, S., AND EMMANOULIDOU, D. Adapting frechet audio distance for generative music evaluation, 2024.
- [3] HIGGINS, I., MATTHEY, L., PAL, A., BURGESS, C., GLOROT, X., BOTVINICK, M., MOHAMED, S., AND LERCHNER, A. beta-vae: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations (ICLR)* (2017).
- [4] KINGMA, D. P., AND WELLING, M. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114* (2013).
- [5] RIERA, P. E., EGUÍA, M. C., AND ZABALJÁUREGUI, M. Timbre spaces with sparse autoencoders. In *16th Brazilian Symposium on Computer Music (SBCM)* (2017).
- [6] RILEY, X., AND DIXON, S. Filobass: A dataset and corpus based study of jazz bass-lines, 2023.
- [7] ROCHE, F., HUEBER, T., LIMIER, S., AND GIRIN, L. Autoencoders for music sound modeling: a comparison of linear, shallow, deep, recurrent and variational models, 2019.
- [8] WILKINS, J., SEETHARAMAN, P., WAHL, A., AND PARDO, B. Vocalset: A singing voice dataset, 2018.
- [9] XI, Q., BITTNER, R. M., PAUWELS, J., YE, X., AND BELLO, J. P. Guitarset dataset, 2019.