



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES
DEPARTAMENTO DE COMPUTACIÓN

Morphing Tímbrico Mediante Interpolación de Pesos de Modelos VAE

Tesis de Licenciatura en Ciencias de la Computación

Facundo González Barnator

Director: Pablo Riera

Codirector: -

Buenos Aires, 2026

MORPHING TÍMBRICO MEDIANTE INTERPOLACIÓN DE PESOS DE MODELOS VAE

El *morphing tímbrico*, la generación de timbres intermedios entre instrumentos conocidos, es una herramienta de interés para la producción musical y el diseño sonoro, ya que permite expandir la paleta sonora más allá de los instrumentos tradicionales. Las técnicas usuales operan en el espacio latente de un único modelo generativo entrenado sobre múltiples instrumentos; si bien un modelo de gran capacidad puede representar varios timbres con fidelidad, en modelos pequeños esta estrategia compromete la fidelidad de cada timbre individual.

En este trabajo se propone un enfoque alternativo: entrenar autoencoders variacionales (β -VAE) especializados por instrumento a partir de un modelo base común, y generar timbres híbridos mediante la interpolación de los pesos de esos modelos.

El sistema se entrena sobre espectrogramas de magnitud obtenidos por STFT de cuatro instrumentos (piano, guitarra, voz y bajo) y se evalúa mediante Fréchet Audio Distance (FAD), similitud coseno sobre *embeddings* MERT, análisis del espacio latente con UMAP y error de reconstrucción.

Palabras claves: morphing tímbrico, autoencoder variacional, β -VAE, interpolación de pesos, síntesis de audio, Fréchet Audio Distance.

MORPHING TÍMBRICO MEDIANTE INTERPOLACIÓN DE PESOS DE MODELOS VAE

Timbre morphing, the generation of intermediate timbres between known instruments, is a tool of interest for music production and sound design, as it allows the sonic palette to be expanded beyond traditional instruments. Common techniques operate in the latent space of a single generative model trained on multiple instruments; while a high-capacity model can represent several timbres with fidelity, in small models this strategy compromises the fidelity of each individual timbre.

This work proposes an alternative approach: training variational autoencoders (β -VAE) specialized per instrument from a common base model, and generating hybrid timbres by interpolating the weights of those models.

The system is trained on magnitude spectrograms obtained via STFT from four instruments (piano, guitar, voice and bass) and is evaluated using Fréchet Audio Distance (FAD), cosine similarity over MERT *embeddings*, latent-space analysis with UMAP and reconstruction error.

Keywords: timbre morphing, variational autoencoder, β -VAE, weight interpolation, audio synthesis, Fréchet Audio Distance.

AGRADECIMIENTOS

A todas las personas que me acompañaron en este camino y que lo hicieron posible.
A Laura y Osvaldo que me inspiraron desde chico la curiosidad por estudiar esta carrera.

A mi hermano Matías y a mis abuelos.

A mi director Pablo por el acompañamiento y la pasión que puso en este trabajo.

A mi abuela Celia. A la memoria de Julio e Irma.

Índice general

1..	Introducción	1
1.1.	Motivación	1
1.2.	Antecedentes	1
1.3.	Propuesta	2
2..	Metodología	3
2.1.	Dataset	3
2.2.	Representación y preprocesamiento del audio	4
2.3.	Autoencoders variacionales	5
2.3.1.	Del autoencoder al enfoque variacional	5
2.3.2.	Formulación probabilística y objetivo variacional	5
2.3.3.	Divergencia KL y regularización del espacio latente	6
2.3.4.	Truco de reparametrización	6
2.3.5.	El hiperparámetro β y el β -VAE	7
2.4.	Arquitectura del modelo VAE	8
2.5.	Estrategia de entrenamiento	10
2.6.	Interpolación de pesos	11
2.7.	Reconstrucción de audio	12
2.8.	Métricas de evaluación	13
3..	Experimentación y resultados	14
3.1.	Exploración de Arquitecturas	14
3.1.1.	Tamaño del espacio latente	14
3.1.2.	Experimentación β -VAE	17
3.2.	Análisis del Espacio Latente	19
3.3.	Interpolación de parámetros	21
3.3.1.	Elección de Métricas de Similitud	21
3.3.2.	Experimentos de Interpolación	23
4..	Conclusiones	27
4.1.	Resumen de resultados	27
4.2.	Contribuciones	27
4.3.	Limitaciones	28
4.4.	Trabajo futuro	28

1. INTRODUCCIÓN

1.1. Motivación

El timbre es el atributo perceptual que permite distinguir dos sonidos de igual altura y volumen producidos por fuentes distintas, por ejemplo una misma nota ejecutada en un piano y en una guitarra. La capacidad de generar timbres intermedios entre instrumentos conocidos, comúnmente denominada *morphing* tímbrico, cobra especial relevancia tanto en la producción musical como en el diseño sonoro, dado que permite expandir la paleta sonora más allá de las limitaciones de los instrumentos tradicionales.

Con el propósito de proveer herramientas para la síntesis de nuevas sonoridades a partir de timbres familiares, resulta de gran interés explorar el potencial generativo de modelos basados en redes neuronales profundas. En particular, este trabajo se enfoca en investigar la factibilidad y eficacia de realizar procesos de interpolación que operen directamente sobre las características tímbricas de señales disímiles.

1.2. Antecedentes

Los autoencoders variacionales (VAE), introducidos por Kingma y Welling [4], constituyen un marco generativo consolidado que aprende representaciones latentes continuas a partir de los datos de entrada. A diferencia de los autoencoders clásicos, el enfoque variacional impone una distribución probabilística sobre el espacio latente mediante la divergencia de Kullback-Leibler (KL). Esto no solo facilita la generación de nuevas muestras, sino que además habilita la interpolación entre ellas. Higgins et al. [3] propusieron el β -VAE, una variante que pondera el término de la divergencia KL mediante un hiperparámetro β . Este factor permite regular el balance entre la calidad de la reconstrucción y la regularización del espacio latente, favoreciendo la emergencia de representaciones más estructuradas cuando $\beta > 0$.

En el ámbito de la síntesis y el modelado de audio musical, Roche et al. [9] realizaron un estudio comparativo de diversas arquitecturas de autoencoders incluyendo configuraciones lineales, superficiales, profundas, recurrentes y variacionales, aplicadas a la representación de espectrogramas de instrumentos musicales. Sus conclusiones demostraron que los modelos variacionales logran el mejor compromiso entre fidelidad de reconstrucción y regularización del espacio latente, sentando un precedente directo para la aplicación de los VAE en el modelado tímbrico.

Posteriormente, orientados al procesamiento en el dominio del audio, Caillon y Esling [1] demostraron con la arquitectura RAVE que los VAE son capaces de sintetizar audio de alta calidad en tiempo real operando directamente sobre representaciones espectrales. Por su parte, Riera, Eguía y Zabaljáuregui [7] exploraron la construcción de espacios tímbricos mediante autoencoders dispersos (*sparse autoencoders*), evidenciando que las representaciones aprendidas capturan las relaciones

perceptuales entre timbres instrumentales de manera consistente con la percepción humana.

1.3. Propuesta

Si bien los antecedentes reseñados demuestran la utilidad de los modelos generativos para representar el timbre, la síntesis de sonoridades intermedias entre instrumentos específicos permanece como un problema abierto. Las técnicas convencionales de interpolación suelen operar dentro del espacio latente de un único modelo entrenado conjuntamente sobre múltiples instrumentos, una estrategia que frecuentemente limita la fidelidad y el detalle de cada timbre individual.

En este trabajo proponemos un enfoque alternativo: entrenar modelos VAE especializados de forma independiente para cada instrumento y, posteriormente, realizar una interpolación en el espacio de sus pesos. De este modo, se generan modelos intermedios cuyos *decoders* producen timbres híbridos. Esta estrategia opera directamente sobre la parametrización del modelo en lugar de hacerlo sobre el espacio latente, buscando preservar la capacidad reconstructiva y la riqueza espectral de cada modelo especializado.

Un criterio que guía el diseño del sistema es mantener modelos de tamaño reducido. Buscamos que sean livianos y fáciles de entrenar, de manera que tanto la inferencia como la interpolación de sus pesos puedan ejecutarse con recursos de hardware modestos y, eventualmente, en tiempo real. Esta orientación condiciona las decisiones de arquitectura y de datos que tomamos a lo largo del trabajo.

El sistema propuesto trabaja con espectrogramas de magnitud obtenidos mediante la Transformada de Fourier de Tiempo Corto (STFT). Estas representaciones son proyectadas por el *encoder* del VAE hacia un espacio latente de baja dimensionalidad (típicamente de 4 dimensiones) y luego reconstruidas por el *decoder*. Para evaluar cuantitativamente la calidad de las interpolaciones resultantes, se utiliza la métrica Fréchet Audio Distance (FAD) [2] combinada con *embeddings* extraídos del modelo MERT. Esto permite medir con rigor la distancia perceptual entre las distribuciones del audio generado y el de referencia.

2. METODOLOGÍA

2.1. Dataset

Un componente fundamental de este trabajo es la construcción del conjunto de datos con el que entrenamos y validamos los modelos. Optamos por trabajar con cuatro instrumentos: piano, guitarra, bajo y voz. Se trata de fuentes sonoras familiares y de timbre fácilmente reconocible, lo que facilita evaluar de manera intuitiva el resultado del *morphing* tímbrico. Si bien tres de ellos pertenecen a la familia de las cuerdas, difieren tanto en el mecanismo de producción del sonido (cuerda percutida en el piano, cuerda pulsada en la guitarra y el bajo) como en su registro, mientras que la voz aporta una fuente de naturaleza distinta. De este modo, los cuatro presentan timbres claramente diferenciables entre sí, condición necesaria para evaluar transiciones tímbricas. A esto se suma la disponibilidad de material grabado de calidad para cada uno de ellos.

Para reunir el material de cada instrumento recurrimos a grabaciones reales provenientes de distintas fuentes:

- **Piano:** armamos un conjunto a partir de interpretaciones de piezas de música clásica de dominio público obtenidas de internet.
- **Guitarra:** utilizamos una sección del dataset GuitarSet [11], restringida a fragmentos de guitarra eléctrica que combinan pasajes melódicos y armónicos (rasgueos, acordes, etc.).
- **Bajo:** extrajimos del dataset FiloBass [8] líneas de bajo y contrabajo de *standards* de jazz conocidos.
- **Voz:** aprovechamos el dataset VocalSet [10], que ofrece abundante material vocal con distintas voces, escalas y melodías. Seleccionamos un subconjunto representativo de cuatro voces (dos masculinas y dos femeninas) que incluye melodías, escalas y arpeggios.

Para cada instrumento recolectamos aproximadamente 87 minutos de audio, lo que totaliza alrededor de 5,8 horas de grabaciones. Mantener una duración equilibrada entre instrumentos evita sesgar el entrenamiento hacia alguno de ellos en particular. Este volumen resulta suficiente para la tarea de entrenamiento y validación propuesta y, al mismo tiempo, mantiene el entrenamiento reproducible sin requerir un costo computacional elevado.

2.2. Representación y preprocesamiento del audio

Las redes neuronales que componen el sistema no operan directamente sobre la forma de onda, sino sobre una representación en el dominio tiempo-frecuencia de la señal. Por ese motivo, antes del entrenamiento cada archivo de audio atraviesa una etapa de preprocesamiento común que describimos a continuación.

En primer lugar, todas las pistas se convierten a un único canal (monofónico) y se remuestrean a una frecuencia de muestreo de 22050 Hz, de modo de unificar el formato de entrada con independencia de la fuente original.

Sobre la señal resultante aplicamos la Transformada de Fourier de Tiempo Corto (STFT), utilizando una ventana de Hann de 2048 muestras (*win length*) y un salto de 512 muestras (*hop length*) entre ventanas consecutivas. La STFT produce, para cada instante de análisis (*frame*), un espectro complejo del cual conservamos por separado la magnitud y la fase.

Dado que la información tímbrica reside principalmente en la distribución de energía espectral, el modelo trabaja únicamente con la magnitud, mientras que la fase se reserva para la etapa de reconstrucción del audio. La magnitud se expresa en escala logarítmica (decibeles) según $S = 10 \log_{10}(|F|^2)$, donde F es el espectro complejo. Esta transformación comprime el rango dinámico de la señal y se ajusta mejor a la forma en que el oído humano percibe la intensidad sonora.

A continuación normalizamos los espectrogramas en dos pasos. Primero recortamos los valores por debajo de un umbral de -60 dB y los desplazamos para que el piso de energía quede en cero, descartando así el ruido de fondo poco significativo. Luego dividimos por el valor máximo global del conjunto, al que llamamos X_{max} , llevando todas las magnitudes al rango $[0, 1]$. Este factor X_{max} se almacena junto con el modelo, ya que es necesario para revertir la normalización al momento de reconstruir el audio.

Cada *frame* del espectrograma constituye entonces un vector de 1025 componentes (correspondiente a $win\ length/2 + 1$ *bins* de frecuencia), que es la unidad de entrada que recibe la red. El autoencoder procesa cada *frame* de forma independiente, sin modelar de manera explícita la evolución temporal entre ellos.

2.3. Autoencoders variacionales

El componente central del sistema es un autoencoder variacional (VAE). Antes de detallar la arquitectura concreta que empleamos, en esta sección presentamos el marco teórico que motiva su elección y que sustenta tanto la función de pérdida como la estrategia de interpolación descritas más adelante.

2.3.1. Del autoencoder al enfoque variacional

Un autoencoder (AE) clásico está compuesto por dos redes que se entrenan de forma conjunta: un *encoder*, que comprime cada entrada en un vector latente de baja dimensión, y un *decoder*, que intenta reconstruir la entrada original a partir de ese vector. El entrenamiento se guía únicamente por un error de reconstrucción, de modo que el *encoder* aprende una correspondencia determinista entre cada entrada y un punto del espacio latente. Nada obliga a que ese espacio quede organizado de forma continua: pueden aparecer regiones "vacías" que no corresponden a ninguna entrada vista durante el entrenamiento y que, por lo tanto, el *decoder* no sabe reconstruir. Esta falta de estructura vuelve poco fiables tanto el muestreo de nuevos puntos como la interpolación entre representaciones, operaciones que resultan centrales para nuestro objetivo.

El autoencoder variacional, introducido por Kingma y Welling [4], aborda esta limitación imponiendo una estructura probabilística sobre el espacio latente. En lugar de asignar a cada entrada un único punto, el VAE le asocia una distribución de probabilidad y regulariza esas distribuciones para que se ajusten a una distribución de referencia común. De este modo el espacio latente resulta continuo y densamente cubierto, propiedad que habilita generar nuevas muestras e interpolar entre representaciones de manera coherente. Esta capacidad es precisamente la que buscamos para el *morphing* tímbrico. La conveniencia de los modelos variacionales para el modelado de sonido fue además comprobada por Roche et al. [9], en donde hallaron que ofrecen el mejor compromiso entre fidelidad de reconstrucción y regularización del espacio latente.

2.3.2. Formulación probabilística y objetivo variacional

El VAE se formula como un modelo generativo de variables latentes. Se asume que los datos se generan a partir de una variable latente z con una distribución *a priori* $p(z)$, que se toma como una gaussiana isotrópica $\mathcal{N}(0, I)$. El *decoder* modela la verosimilitud $p(x | z)$, es decir, cómo se reconstruye una entrada a partir de un punto del espacio latente, mientras que el *encoder* modela la distribución *a posteriori* aproximada $q(z | x)$, que estima qué valores latentes explican una entrada dada.

Idealmente ajustaríamos el modelo maximizando la verosimilitud de los datos, pero su cálculo exacto es intratable. En su lugar, el VAE maximiza una cota inferior de dicha verosimilitud, conocida como *Evidence Lower Bound* (ELBO):

$$\mathcal{L}_{\text{ELBO}} = E_{q(z|x)}[\log p(x | z)] - D_{\text{KL}}(q(z | x) \| p(z)). \quad (2.1)$$

El primer término premia la calidad de la reconstrucción: mide cuán probable es recuperar la entrada x a partir de los valores latentes muestreados. El segundo término, la divergencia de Kullback-Leibler (KL), penaliza que la distribución *a posteriori* $q(z | x)$ se aleje de la distribución *a priori* $p(z)$, actuando como regularizador del espacio latente. Maximizar el ELBO equivale a minimizar su negativo, esto es, minimizar la suma del error de reconstrucción y el término de regularización. Bajo el supuesto de una verosimilitud gaussiana, el término de reconstrucción se reduce a un error cuadrático medio entre la entrada y su reconstrucción, lo que conecta directamente esta formulación con la función de pérdida que utilizamos en la práctica (Sección 2.5).

2.3.3. Divergencia KL y regularización del espacio latente

La divergencia de Kullback-Leibler cuantifica cuánto se aparta una distribución de otra de referencia. En el VAE mide la distancia entre la distribución *a posteriori* $q(z | x)$ que produce el *encoder* y el *a priori* $\mathcal{N}(0, I)$. Al incorporarla al objetivo, se fuerza a que las distribuciones latentes de todas las entradas se concentren en torno a una misma gaussiana estándar, haciéndolas solaparse y organizarse alrededor del origen. Este efecto es el que dota de continuidad al espacio latente y lo cubre densamente, evitando las regiones "vacías" propias del autoencoder clásico, característica que creemos deseable para la interpolación propuesta. Para distribuciones gaussianas, la divergencia KL respecto de $\mathcal{N}(0, I)$ admite una forma cerrada, que es la que se computa durante el entrenamiento:

$$\mathcal{L}_{\text{KL}} = -\frac{1}{2} \sum_j \left(1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2 \right), \quad (2.2)$$

donde μ_j y σ_j^2 son la media y la varianza de la j -ésima dimensión latente.

2.3.4. Truco de reparametrización

Para obtener el vector latente z es necesario muestrear de la distribución $q(z | x)$, operación que en principio no es diferenciable y bloquearía el entrenamiento por descenso de gradiente. El truco de reparametrización (*reparameterization trick*) [4] resuelve este problema expresando la muestra como una transformación determinista de los parámetros de la distribución más una fuente de ruido externa:

$$z = \mu + \varepsilon \odot \exp \left(\frac{1}{2} \log \sigma^2 \right), \quad \varepsilon \sim \mathcal{N}(0, I). \quad (2.3)$$

De este modo el muestreo conserva la diferenciable necesaria para propagar el gradiente a través del *encoder*. En el caso particular en que se desactiva la regularización ($\beta = 0$), el modelo se comporta como un autoencoder determinista y se toma directamente $z = \mu$.

2.3.5. El hiperparámetro β y el β -VAE

Higgins et al. [3] propusieron el β -VAE, una generalización del objetivo del VAE que introduce un factor escalar β ponderando el término de la divergencia KL:

$$\mathcal{L} = \mathcal{L}_{\text{rec}} + \beta \mathcal{L}_{\text{KL}}. \quad (2.4)$$


El valor de β regula el equilibrio entre la fidelidad de la reconstrucción y la regularización del espacio latente. Con $\beta = 1$ se recupera el VAE estándar, mientras que valores de β mayores imponen una mayor presión sobre el espacio latente, favoreciendo representaciones más estructuradas a costa de degradar la reconstrucción.

En el extremo, con $\beta = 0$ el término KL desaparece y el modelo se reduce a un autoencoder determinista (AE). La elección concreta del valor de β se aborda empíricamente en el Capítulo 3.

2.4. Arquitectura del modelo VAE

La arquitectura que empleamos instancia el marco descrito en la sección anterior mediante dos redes que se entrenan de forma conjunta: un *encoder*, que comprime cada espectrograma de entrada en una representación latente de baja dimensión, y un *decoder*, que reconstruye el espectrograma original a partir de dicha representación. La figura 2.1 esquematiza la arquitectura completa.

Fig. 2.1: Arquitectura general del autoencoder variacional: el *encoder* reduce el espectrograma de entrada hasta un espacio latente de dimensión 4 y el *decoder* lo reconstruye de forma espejada.



El *encoder* está formado por una sucesión de capas totalmente conectadas que reducen progresivamente la dimensionalidad de la entrada, partiendo de los 1025 valores del espectrograma hasta alcanzar el espacio latente. Cada capa intermedia combina una transformación lineal, una normalización por lotes (*Batch Normalization*) y una activación no lineal ELU (*Exponential Linear Unit*). Tal como se describió en la sección anterior, el *encoder* variacional no produce un único vector latente, sino dos: un vector de medias μ y un vector de logaritmos de varianza $\log \sigma^2$, que en conjunto parametrizan una distribución gaussiana sobre el espacio latente. A partir de estos parámetros se obtiene el vector latente z mediante el truco de reparametrización descrito en la Sección 2.3.

El *decoder* replica la estructura del *encoder* de forma espejada: a partir del vector latente z expande progresivamente la dimensionalidad mediante capas lineales con *Batch Normalization* y activaciones ELU, hasta reconstruir un vector de 1025 componentes que representa la magnitud espectral estimada. La capa final no incorpora activación no lineal, de modo de no restringir el rango de los valores reconstruidos. En la mayoría de los experimentos utilizamos un espacio latente de dimensión 4, valor que justificamos empíricamente en el Capítulo 3.

2.5. Estrategia de entrenamiento

La función de pérdida que minimizamos es el negativo del ELBO presentado en la Sección 2.3, con la divergencia KL ponderada por el hiperparámetro β (esto es, $\mathcal{L} = \mathcal{L}_{\text{rec}} + \beta \mathcal{L}_{\text{KL}}$). En la práctica, el término de reconstrucción se calcula como el error cuadrático medio (MSE) entre el espectrograma de entrada x y su reconstrucción $\hat{x}$:

$$\mathcal{L}_{\text{rec}} = \frac{1}{N} \sum_i (x_i - \hat{x}_i)^2, \quad (2.5)$$

mientras que el término de regularización $\mathcal{L}_{\text{KL}}$ es la divergencia KL en su forma cerrada, definida en la Sección 2.3. La elección del valor de β se aborda en el Capítulo 3.

El entrenamiento de los modelos especializados por instrumento se organiza en dos etapas, que dan lugar a dos estrategias de inicialización. En la primera, la más directa, entrenamos cada modelo desde una inicialización aleatoria utilizando únicamente los datos del instrumento correspondiente. Nos referiremos a estos modelos como entrenados desde cero (*Scratch*).

En la segunda etapa adoptamos un enfoque más sofisticado basado en *fine-tuning*. Primero entrenamos un *modelo base* sobre el conjunto completo de los cuatro instrumentos, de modo que aprenda una representación tímbrica general. Luego, tomando ese modelo base como punto de partida común (*Checkpoint*), especializamos un modelo por instrumento ajustando sus pesos sobre los datos específicos de cada uno.

Combinando estas dos estrategias de inicialización (*Scratch* y *Checkpoint*) con las dos opciones de regularización del espacio latente, autoencoder clásico ($\beta = 0$, AE) o β -VAE ($\beta = 0,001$), obtenemos cuatro configuraciones por instrumento que comparamos en la experimentación.

En todos los casos optimizamos los parámetros con el algoritmo Adam y una tasa de aprendizaje de 10^{-3} , dividiendo los datos en un 95 % para entrenamiento y un 5 % para validación, y procesándolos en lotes (*batches*) de 256 ejemplos. Para evitar el sobreajuste empleamos *early stopping*, deteniendo el entrenamiento cuando el error de validación deja de mejorar durante un número prefijado de épocas. Adicionalmente, aplicamos recorte de gradiente (*gradient clipping*) para estabilizar la optimización.

2.6. Interpolación de pesos

Una vez entrenados los modelos especializados por instrumento, generamos timbres híbridos interpolando directamente en el espacio de sus pesos. Dados dos modelos con arquitectura idéntica, un modelo origen A y un modelo destino B, y un coeficiente de interpolación $\alpha \in [0, 1]$, construimos un tercer modelo cuyos parámetros son una combinación de los de A y B. Por construcción, $\alpha = 0$ reproduce exactamente el modelo A y $\alpha = 1$ el modelo B, mientras que los valores intermedios producen *decoders* que sintetizan timbres mixtos.

La interpolación se realiza parámetro por parámetro, y exploramos dos alternativas para combinar cada tensor de pesos: una interpolación lineal (LERP) y una interpolación esférica (SLERP, *Spherical Linear Interpolation*).

La interpolación lineal calcula directamente el promedio ponderado entre los pesos de ambos modelos, $(1 - \alpha)w_A + \alpha w_B$. La interpolación esférica, en cambio, recorre el arco que une ambos vectores sobre la hiperesfera en lugar de hacerlo en línea recta; su motivación es producir transiciones más suaves entre los modelos. Aplanando cada tensor a un vector, llamando w_A y w_B a los vectores de pesos de cada modelo y θ al ángulo que forman entre sí, esta última se define como:

$$\text{SLERP}(w_A, w_B, \alpha) = \frac{\sin((1 - \alpha)\theta)}{\sin \theta} w_A + \frac{\sin(\alpha\theta)}{\sin \theta} w_B. \quad (2.6)$$

Existe un caso particular a tener en cuenta: cuando ambos vectores son prácticamente paralelos (ángulo muy pequeño), el cómputo de SLERP se vuelve numéricamente inestable, por lo que en esa situación recurrimos a la interpolación lineal. De este modo, las dos configuraciones que comparamos son una interpolación puramente lineal y una interpolación esférica que recae en la lineal únicamente cuando resulta necesario. Finalmente, los parámetros que no son de punto flotante, como los contadores internos de la normalización por lotes, no se interpolan: simplemente se toma el valor del modelo más cercano según α .

2.7. Reconstrucción de audio

Para escuchar el resultado de un modelo, ya sea uno especializado o uno interpolado, debemos convertir su salida nuevamente en una forma de onda. El *decoder* produce un espectrograma de magnitud normalizado, que primero reescalamos multiplicando por el factor X_{max} y luego llevamos de la escala logarítmica a magnitud lineal, deshaciendo la normalización aplicada durante el preprocesamiento.

El principal desafío de esta etapa es que el modelo reconstruye únicamente la magnitud del espectro, pero la STFT inversa requiere también la información de fase. Para recuperarla evaluamos distintas estrategias:

- **Griffin-Lim**: algoritmo iterativo que estima una fase coherente con la magnitud dada.
- **PGHI** (*Phase Gradient Heap Integration*) [6]: método basado en el gradiente de fase que la reconstruye en una única pasada.
- **Fase aleatoria**: se asigna una fase aleatoria a cada componente; es la opción más rápida pero de menor calidad.

Una vez combinadas la magnitud reconstruida y la fase estimada, aplicamos la STFT inversa (con la misma ventana de Hann y los mismos parámetros utilizados en el análisis) para obtener la forma de onda final.

2.8. Métricas de evaluación

Para evaluar el sistema de manera cuantitativa recurrimos a un conjunto de métricas complementarias, cada una orientada a un aspecto distinto del problema.

Error de reconstrucción (MSE). Durante la exploración de arquitecturas medimos la calidad de la reconstrucción mediante el error cuadrático medio sobre el conjunto de validación, lo que nos permite comparar modelos con distintos tamaños de espacio latente y distintos valores de β .

Distancia de Fréchet para Audio (FAD). Para cuantificar la similitud tímbrica entre audios utilizamos la *Fréchet Audio Distance*, que compara las distribuciones de *embeddings* de dos conjuntos de audio en lugar de hacerlo muestra a muestra. Los *embeddings* se extraen con el modelo preentrenado MERT [5] (MERT-v1-95M). Modelando cada distribución como una gaussiana de media μ y matriz de covarianza Σ , la FAD se define como:

$$\text{FAD} = \|\mu_a - \mu_b\|^2 + \text{tr}(\Sigma_a + \Sigma_b - 2(\Sigma_a \Sigma_b)^{1/2}). \quad (2.7)$$

Como la FAD es una distancia (cuanto menor, más parecidos son los audios), la transformamos en una medida de similitud acotada mediante $\text{sim} = \exp(-\text{FAD}/k)$, de modo que los valores cercanos a 1 indican gran parecido tímbrico.

Similitud coseno. Como métrica alternativa consideramos la similitud coseno entre los *embeddings* promedio de MERT de dos audios. En la experimentación contrastamos su comportamiento con el de la FAD para justificar la elección de esta última.

Visualización con UMAP. Para analizar de forma cualitativa la organización del espacio latente proyectamos los *embeddings* latentes a dos dimensiones mediante UMAP, etiquetando cada punto según su instrumento. Esto permite observar visualmente si los instrumentos forman agrupamientos (*clusters*) diferenciados.

Separación entre *clusters* (U de Wilcoxon-Mann-Whitney). Para complementar el análisis visual de UMAP con una medida cuantitativa de cuán separados están los *clusters* de cada par de instrumentos, empleamos una versión multidimensional del estadístico U de Wilcoxon-Mann-Whitney. Este estadístico toma valores entre 0,5 (los dos grupos son indistinguibles) y 1 (separación total), y lo resumimos en una matriz de separación por pares de instrumentos.

3. EXPERIMENTACIÓN Y RESULTADOS


3.1. Exploración de Arquitecturas

3.1.1. Tamaño del espacio latente

Uno de los aspectos clave a definir en la arquitectura de los modelos es el tamaño del espacio latente. Como cabe esperar, a mayor dimensión del espacio latente menor es el error de reconstrucción; sin embargo, para el uso práctico de estos modelos resulta deseable mantener un tamaño acotado, de modo que las representaciones sean fáciles de manipular. Si pensamos en una implementación basada en perillas para modificar el espacio latente, contar con 4 perillas resulta coherente, mientras que tener 32 puede resultar poco intuitivo.

Con el objetivo de encontrar el tamaño ideal, experimentamos con dimensiones 2, 3, 4, 6 y 8, y graficamos el error de reconstrucción sobre el conjunto de validación para cada modelo (los modelos por instrumento y el modelo base). El propósito es verificar que el error disminuya a medida que la dimensión del espacio latente aumenta y, a la vez, evaluar si es posible evitar dimensiones tan grandes como 8 manteniendo una performance aceptable.

Fig. 3.1: Error de Reconstrucción (MSE) vs Dimensión de espacio latente, $\beta = 0$




Analizando los resultados de las figuras 3.1 y 3.2 observamos que, con un espacio latente de dimensión 4, obtenemos una ganancia significativa respecto a las


dimensiones 2 y 3, mientras que aumentar el tamaño a 6 u 8 no aporta una mejora relevante.

Nos interesa también verificar este comportamiento para la arquitectura β -VAE, donde esperamos observar un error de reconstrucción mayor en magnitud ya que la *loss* de estos modelos incorpora también la divergencia KL pero con la misma tendencia.

Fig. 3.2: Error de Reconstrucción promedio general



En efecto, lo observado para los modelos AE (con $\beta = 0$) se cumple también con β activado. Resta verificar el comportamiento de la divergencia KL en los modelos β -VAE para los distintos tamaños de espacio latente, presentado en la figura 3.3.

Fig. 3.3: Divergencia KL vs Dimensión de espacio latente, $\beta = 0,001$ 

Efectivamente, el salto más significativo se encuentra entre las dimensiones 2 y 4, y a partir de allí la KL sigue disminuyendo pero con una ganancia relativa menor.

Para concluir este análisis, queremos asegurarnos de que este comportamiento es consistente para todos los modelos por separado. En la figura 3.4 se presenta el desglose del error de reconstrucción por instrumento y modelo base, que confirma la misma tendencia.




Fig. 3.4: Desglose: Error de Reconstrucción (MSE) por modelo

Corroboramos así que todos los modelos reportan el mismo comportamiento frente al aumento de tamaño del espacio latente. En base a estos resultados, adoptamos para el resto de los experimentos arquitecturas con espacio latente de dimensión 4.

3.1.2. Experimentación β -VAE

Definido el tamaño del espacio latente, resta fijar el grado de regularización del mismo. Con el fin de regularizar el espacio latente sin degradar excesivamente la calidad de la reconstrucción, buscamos determinar un valor adecuado para el hiperparámetro β . Para ello, realizamos un barrido experimental evaluando cinco valores distintos: $\beta \in [0, 10^{-5}, 10^{-4}, 10^{-3}, 10^{-2}]$. Para cada uno de ellos, se calculó el promedio del error de reconstrucción (MSE) y de la divergencia KL sobre el último 10% del entrenamiento. A partir de estos resultados, construimos las curvas de compromiso entre ambos términos que se exponen en la figura 3.5, donde el punto de interés es el que se ubica en el "codo" de la curva.





Fig. 3.5: Curva de compromiso entre error de reconstrucción y divergencia KL para la selección del hiperparámetro β .

La comparación entre ambas representaciones resulta de especial utilidad para analizar el impacto de desactivar la regularización ($\beta = 0$). En la figura 3.5a, la visualización en escala lineal obligó a excluir el caso $\beta = 0$ debido a que la divergencia KL en este escenario alcanza valores sumamente elevados que distorsionan la escala del eje, agrupando al resto de los puntos contra el eje de ordenadas. Sin embargo, al aplicar una escala Log-Log en ambos ejes (figura 3.5b), logramos incorporar este caso límite y visualizar en un mismo plano magnitudes que difieren en varios órdenes de escala.


A partir de este análisis, se observa claramente que $\beta = 0,001$ se sitúa en el “codo” de la curva, representando el mejor punto de compromiso (*trade-off*) del sistema. Por un lado, aumentar la regularización a $\beta = 0,01$ penaliza excesivamente la fidelidad del modelo, incrementando notablemente el error de reconstrucción. Por el otro, relajar la regularización a $\beta = 0,0001$ o $\beta = 0,00001$ genera un incremento desmedido en la divergencia KL, aproximándose al comportamiento desregulado de un autoencoder tradicional ($\beta = 0$) sin aportar una mejora sustancial en el error de reconstrucción. Este análisis cuantitativo se complementó con escuchas subjetivas de las reconstrucciones obtenidas con $\beta = 0,001$, confirmando que el nivel de error alcanzado bajo esta configuración permite reproducir los audios de entrenamiento de forma prácticamente indistinguible respecto a los resultados del caso $\beta = 0$.

3.2. Análisis del Espacio Latente

Para analizar la organización del espacio latente del modelo base, proyectamos los *embeddings* a 2 dimensiones mediante UMAP, configurado con un número de vecinos ($n_neighbors$) de 15, y etiquetando cada muestra con el instrumento al que corresponde. Esto nos permite evaluar visualmente si los distintos instrumentos forman *clusters* diferenciados y comparar el comportamiento entre las configuraciones $\beta = 0$ y $\beta = 0,001$. Los resultados se presentan en la figura 3.6.





(a) $\beta = 0,001$.



(b) $\beta = 0$.

Fig. 3.6: Proyección a 2 dimensiones del espacio latente del modelo base utilizando UMAP ($n_neighbors = 15$).

Para cuantificar la separación entre los *clusters* de cada instrumento computamos, para cada par, el estadístico U de Wilcoxon-Mann-Whitney multidimensional sobre la proyección UMAP, sintetizado en la matriz de la figura 3.7. Recordemos que este estadístico vale 0,5 cuando los dos grupos son indistinguibles y 1 cuando se encuentran completamente separados. Dado que en la figura 3.6 los instrumentos ya aparecen formando agrupamientos bien diferenciados, esperamos obtener valores cercanos a 1 para todos los pares en ambas configuraciones.

(a) $\beta = 0,001$.(b) $\beta = 0$.Fig. 3.7: Matriz de separación entre *clusters* de instrumentos en la proyección UMAP.

Los resultados obtenidos confirman que en ambas configuraciones se observa un alto nivel de separación entre instrumentos, con valores próximos a 1 para todos los pares. No obstante, la separación resulta consistentemente algo menor en el modelo con $\beta = 0,001$ que en el modelo sin regularización, comportamiento que se puede explicar con el hecho de que la regularización produce un espacio latente más suavizado y continuo. Por ejemplo, para el par bajo-voz el estadístico desciende de 0,926 en el caso $\beta = 0$ a 0,796 con $\beta = 0,001$.

3.3. Interpolación de parámetros

Esta sección se centra en la interpolación de pesos entre dos modelos especializados en instrumentos distintos. Tal como se definió en la sección de metodología, generaremos un modelo intermedio en función de tres parámetros: un modelo origen A, un modelo destino B y un coeficiente de interpolación $\alpha \in [0, 1]$. De este modo, con $\alpha = 0$ obtenemos exactamente el modelo A, y con $\alpha = 1$ obtenemos el modelo B.

El objetivo principal de esta interpolación es lograr una transferencia tímbrica suave entre ambos modelos. Por ejemplo, si establecemos un modelo de voz como modelo A y un modelo de piano como modelo B, el comportamiento esperado es que, a medida que α se incrementa de 0 a 1, el audio sintetizado adquiera progresivamente características tímbricas más cercanas a las del piano.

A lo largo de los experimentos, analizaremos el impacto de las distintas configuraciones de entrenamiento introducidas previamente. Para mantener la consistencia, clasificaremos los modelos según su inicialización: desde cero (*Scratch*) o desde un modelo base pre-entrenado (*Checkpoint*); y según su regularización en el espacio latente: Autoencoder estándar (AE, con $\beta = 0$) o β -VAE (con $\beta = 0,001$).

3.3.1. Elección de Métricas de Similitud


Para evaluar empíricamente la interpolación, resulta indispensable definir una métrica que cuantifique la similitud tímbrica entre la salida de los modelos y los audios de referencia. En este trabajo, comparamos el desempeño de dos enfoques: la similitud coseno entre embeddings extraídos con MERT, y la Distancia de Fréchet para Audio (FAD, por sus siglas en inglés) [2], la cual es altamente citada en la literatura sobre el tema.

La principal diferencia teórica entre ambas recae en que FAD considera la varianza de las distribuciones, lo que a priori mejoraría su precisión al evaluar fragmentos de audio de mayor duración. Sin embargo, en instantes de audio cortos (pocos frames de sonido constante) donde prima el análisis tímbrico, ambas métricas deberían ofrecer resultados comparables.


El propósito de este experimento no es comparar configuraciones de entrenamiento, sino observar cómo se comportan ambas métricas frente a un mismo escenario de interpolación, para decidir en cuál de ellas nos apoyaremos en el resto del análisis. Evaluamos la interpolación de voz a piano tomando como referencia el audio reconstruido por el modelo de piano, y analizamos dos formas de generar la entrada del *decoder*: a partir de un vector latente Z aleatorio fijo, que al repetirse a lo largo de varios *frames* produce un audio de timbre constante, y a partir de un vector latente Z obtenido al codificar un fragmento de audio de validación, que en cambio describe una trayectoria a través del espacio latente.

Nuestra hipótesis es que la similitud coseno se comportará de manera adecuada en el escenario estático del vector aleatorio, pero resultará más errática al seguir una trayectoria del espacio latente, mientras que FAD debería mantenerse estable

en ambos casos. Para poner a prueba las métricas bajo condiciones distintas, incluimos dos configuraciones de entrenamiento de comportamiento opuesto: *Scratch-AE* ($\beta = 0$), que anticipamos como desfavorable, y *Checkpoint- β -VAE* ($\beta = 0,001$), que esperamos favorable.




(a) Configuración: *Scratch-AE* ($\beta = 0$).




(b) Configuración: *Checkpoint- β -VAE* ($\beta = 0,001$).

Fig. 3.8: Comparación de métricas (Similitud Coseno vs. FAD) partiendo de un vector latente Z aleatorio.

Los resultados presentados en la Figura 3.8 ilustran el comportamiento partiendo de un Z aleatorio. Para la configuración *Scratch-AE*, es esperable que no haya una transición suave (ya que interpolamos espacios latentes disjuntos y sin regularizar); no obstante, se observa que la similitud coseno presenta picos y fluctuaciones erráticas, mientras que FAD se mantiene notablemente más estable. Por el contrario, en la configuración *Checkpoint- β -VAE*, ambas métricas muestran el crecimiento suave y sostenido esperado, presentando una alta correlación en este escenario estático.



(a) Configuración: *Scratch-AE* ($\beta = 0$).



(b) Configuración: *Checkpoint- β -VAE* ($\beta = 0,001$).

Fig. 3.9: Comparación de métricas (Similitud Coseno vs. FAD) partiendo de un vector latente Z codificado desde un audio real.

Al evaluar con un vector latente Z proveniente de un audio real (Figura 3.9), las deficiencias de la similitud coseno se hacen más evidentes. En la configuración *Scratch-AE*, la similitud coseno sufre una alta variación y dispersión. FAD, en cambio, captura correctamente que el modelo no logra asimilarse al timbre destino hasta llegar a $\alpha \approx 0,95$.

En la configuración *Checkpoint- β -VAE*, FAD traza una curva de crecimiento predecible y suave con baja desviación estándar, confirmando que la interpolación es efectiva. La similitud coseno, aunque logra marcar la tendencia general de transferencia tímbrica, presenta caídas anómalas (e.g., en $\alpha = 0,20$) y mayor dispersión. Dado que FAD demostró ser más robusta y consistente frente a distintas entradas y configuraciones, nos basaremos en ella para el resto de los experimentos de esta sección.

3.3.2. Experimentos de Interpolación

Habiendo validado la métrica, procedemos a verificar si la transferencia tímbrica hacia un instrumento de destino (piano) se sostiene independientemente del instrumento de origen (bajo, guitarra, voz). Evaluamos múltiples muestras de vectores Z para cada caso y graficamos el promedio de la similitud FAD junto con su dispersión.






Fig. 3.10: Comparación agregada entre configuraciones, interpolando desde múltiples instrumentos hacia piano.

Como se observa en la Figura 3.10, existe una transferencia tímbrica en todos los escenarios, pero las diferencias de rendimiento entre configuraciones son notables.

La curva de mejor comportamiento corresponde a *Checkpoint- β -VAE* ($\beta = 0,001$), seguida por *Scratch- β -VAE*. Esto sugiere fuertemente que la regularización impuesta por $\beta > 0$ para suavizar el espacio latente es el factor de mayor impacto para lograr interpolaciones de alta calidad. Secundariamente, compartir un punto de partida común en los pesos del modelo (*Checkpoint*) aporta una mejora adicional frente a los modelos entrenados desde cero.



(a) *Checkpoint- β -VAE* ($\beta = 0,001$).



(b) *Scratch-AE* ($\beta = 0$).

Fig. 3.11: Desglose por instrumento de origen para las distintas configuraciones evaluadas.

Al desglosar los resultados (Figuras 3.11a y 3.11b), confirmamos que este patrón es consistente para cualquier instrumento de origen. Queda en evidencia que los modelos sin regularizar (*Scratch-AE*) fracasan en realizar una transición gradual, retrasando el cambio tímbrico hacia los valores extremos de α .

Hasta aquí fijamos el piano como único instrumento de destino. Para descartar que el comportamiento observado dependa de esa elección, repetimos el análisis tomando cada instrumento como destino y, en cada caso, los tres instrumentos restantes como origen. Promediando sobre todas estas combinaciones obtenemos la comparación de la figura 3.12.




Fig. 3.12: Comparación agregada entre configuraciones, interpolando desde múltiples instrumentos hacia todos los instrumentos.

El resultado confirma el patrón ya observado: a lo largo de las distintas muestras y de todas las combinaciones de instrumentos de origen y destino, la mejor configuración sigue siendo *Checkpoint- β -VAE*. Tanto incorporar únicamente la regularización (β) como partir únicamente de un *checkpoint* común mejoran la similitud respecto del peor enfoque, *Scratch-AE*. Esta tendencia se mantiene de forma consistente con independencia del par origen/destino considerado, lo que indica que las conclusiones anteriores no son un artefacto de haber fijado el piano como destino.

Para dar el análisis por concluido, resta verificar una última condición: a medida que el audio sintetizado se aproxima tímbricamente al instrumento B, debe necesariamente alejarse de las características del instrumento A, y, fundamentalmente, no debe adoptar rasgos de otros instrumentos ajenos a la interpolación (un instrumento *testigo*).

Se espera que, a medida que α crezca, la similitud con el instrumento B aumente y la del instrumento A disminuya, cruzándose aproximadamente en $\alpha = 0,5$. Simultáneamente, la similitud con el instrumento testigo debería mantenerse constante. Para este experimento definimos piano como instrumento A, guitarra como instrumento B, y voz como instrumento testigo.




Fig. 3.13: Transición cruzada de piano a guitarra. Comparación entre orígenes (*Checkpoint* vs. *Scratch*) y regularización (β). La voz actúa como instrumento testigo.

Los resultados presentados en la Figura 3.13 corroboran nuestra hipótesis para la configuración *Checkpoint- β -VAE*. Se observa que la similitud con el piano decrece de manera consistente mientras la similitud con la guitarra aumenta, ocurriendo el punto de cruce alrededor de $\alpha = 0,5$, todo esto mientras la voz (instrumento testigo) se mantiene constante.

Por el contrario, los modelos entrenados desde *Scratch* exhiben un comportamiento indeseable. Aún con $\beta = 0,001$, la transferencia es poco consistente para valores intermedios de α ; y con $\beta = 0$, la transición es prácticamente inexistente hasta $\alpha > 0,8$. El caso de *Checkpoint-AE* ($\beta = 0$) logra la transferencia deseada, pero de forma mucho más abrupta, provocando además fluctuaciones erráticas en la curva del instrumento testigo.

En conclusión, estos experimentos confirman empíricamente que la arquitectura más robusta para garantizar una transferencia tímbrica predecible, gradual e independiente en la interpolación de pesos es la basada en modelos con inicialización común y espacios latentes regularizados (*Checkpoint* con $\beta = 0,001$).

4. CONCLUSIONES

4.1. Resumen de resultados

A lo largo de este trabajo desarrollamos y validamos una técnica para sintetizar timbres intermedios entre instrumentos mediante la interpolación de los pesos de modelos VAE especializados. A diferencia de las técnicas convencionales, que operan dentro del espacio latente de un único modelo entrenado sobre múltiples instrumentos, nuestro enfoque entrena un modelo independiente por instrumento e interpola directamente sobre su parametrización, generando *decoders* intermedios capaces de producir timbres híbridos.

Los experimentos presentados en el Capítulo 3 nos permitieron tomar las decisiones de diseño del sistema y verificar su comportamiento. Determinamos que un espacio latente de dimensión 4 ofrece el mejor compromiso entre fidelidad de reconstrucción y manipulabilidad, y que un valor de regularización de $\beta = 0,001$ se ubica en el codo de la curva de compromiso, equilibrando el error de reconstrucción y la divergencia KL.

El hallazgo central es que la calidad de la interpolación tímbrica depende fuertemente de la configuración de entrenamiento. La combinación de regularizar el espacio latente con un β -VAE y partir de un modelo base común mediante *fine-tuning* (configuración *Checkpoint- β -VAE*) produjo de manera consistente las transiciones más suaves y predecibles. Esta superioridad se manifestó tanto en las métricas cuantitativas, principalmente la *Fréchet Audio Distance* (FAD), como en el análisis subjetivo de escucha de los audios generados, donde la transición entre timbres resultó perceptualmente más gradual y natural.

4.2. Contribuciones

La principal contribución de esta tesis es la propuesta y validación de una técnica novedosa de *morphing* tímbrico basada en la interpolación de pesos entre modelos VAE especializados por instrumento, en lugar de la interpolación en el espacio latente habitual en la literatura.

Como contribución complementaria, aportamos evidencia empírica de que dos factores resultan determinantes para obtener interpolaciones de alta calidad: la regularización del espacio latente mediante β -VAE y la inicialización de los modelos a partir de un punto de partida común (*Checkpoint*). De ambos, la regularización demostró ser el factor de mayor impacto. Asimismo, mostramos que la FAD, combinada con *embeddings* del modelo MERT, constituye una métrica robusta y consistente para evaluar la similitud tímbrica, superando a la similitud coseno en estabilidad frente a distintas entradas y configuraciones.

4.3. Limitaciones

Una decisión de diseño deliberada de este trabajo fue trabajar con modelos pequeños y una cantidad acotada de datos (aproximadamente 87 minutos por instrumento y cuatro instrumentos en total). El objetivo fue obtener modelos fáciles de entrenar, livianos y capaces de ejecutarse localmente en hardware no especialmente potente. Esta decisión está alineada con uno de los focos del proyecto: poder construir, a futuro, una herramienta que utilice estos modelos para la síntesis de audio en tiempo real.

Como contrapartida, este compromiso impone límites sobre la fidelidad y la generalidad alcanzables. El tamaño reducido del conjunto de datos y de las arquitecturas acota la riqueza espectral que los modelos pueden capturar, y el conjunto de cuatro instrumentos restringe la variedad de timbres disponibles para interpolar. Entendemos estas limitaciones como un equilibrio consciente entre la calidad y la viabilidad de un uso liviano y en tiempo real, más que como una restricción intrínseca del método propuesto.

4.4. Trabajo futuro

A partir de los resultados obtenidos, identificamos varias líneas de trabajo futuro:

- **Inferencia e interpolación en tiempo real:** llevar la ejecución de los modelos y la interpolación de sus pesos a un funcionamiento en tiempo real, requisito fundamental para su uso en contextos de interpretación y producción musical.
- **Integración en herramientas de audio:** desarrollar herramientas que permitan utilizar estos modelos dentro de programas de producción musical, por ejemplo como *plugins* en formato VST.
- **Ampliación del dataset y de los instrumentos:** incorporar más instrumentos y una mayor cantidad de datos para mejorar la calidad de los modelos y habilitar un número más amplio de combinaciones tímbricas.
- **Interpolación múltiple:** extender la técnica a una interpolación triple que permita mezclar tres modelos en función de dos parámetros de control.

Bibliografía

- [1] CAILLON, A., AND ESLING, P. Rave: A variational autoencoder for fast and high-quality neural audio synthesis. *arXiv preprint arXiv:2111.05011* (2021).
- [2] GUI, A., GAMPER, H., BRAUN, S., AND EMMANOUILIDOU, D. Adapting frechet audio distance for generative music evaluation, 2024.
- [3] HIGGINS, I., MATTHEY, L., PAL, A., BURGESS, C., GLOT, X., BOTVINICK, M., MOHAMED, S., AND LERCHNER, A. beta-vae: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations (ICLR)* (2017).
- [4] KINGMA, D. P., AND WELING, M. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114* (2013).
- [5] LI, Y., YUAN, R., ZHANG, G., MA, Y., CHEN, X., YIN, H., XIAO, C., LIN, C., RAGNI, A., BENETOS, E., GYENGÉ, N., DANNENBERG, R., LIU, R., CHEN, W., XIA, G., SHI, Y., HUANG, W., WANG, Z., GUO, Y., AND FU, J. Mert: Acoustic music understanding model with large-scale self-supervised training, 2023.
- [6] PRŮŠA, Z., BALAZS, P., AND SØNDERGAARD, P. L. A non-iterative method for (re)construction of phase from stft magnitude. *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 25, 5 (2017), 1154–1164.
- [7] RIERA, P. E., EGUÍA, M. C., AND ZABALJÁUREGUI, M. Timbre spaces with sparse autoencoders. In *16th Brazilian Symposium on Computer Music (SBCM)* (2017).
- [8] RILEY, X., AND DIXON, S. Filobass: A dataset and corpus based study of jazz basslines, 2023.
- [9] ROCHE, F., HUEBER, T., LIMIER, S., AND GIRIN, L. Autoencoders for music sound modeling: a comparison of linear, shallow, deep, recurrent and variational models, 2019.
- [10] WILKINS, J., SEETHARAMAN, P., WAHL, A., AND PARDO, B. Vocalset: A singing voice dataset, 2018.
- [11] XI, Q., BITTNER, R. M., PAUWELS, J., YE, X., AND BELLO, J. P. Guitarset dataset, 2019.