Universidad de Buenos Aires
Facultad de Ciencias Exactas y Naturales
Departamento de Computación

Morphing Tímbrico Mediante Interpolación de Pesos de Modelos VAE

Tesis de Licenciatura en Ciencias de la Computación

Facundo González Barnator

Director: Pablo Riera

Codirector: -

Buenos Aires, 2026

MORPHING TÍMBRICO MEDIANTE INTERPOLACIÓN DE PESOS DE MODELOS VAE

El *morphing tímbrico*— la generación de timbres intermedios entre instrumentos conocidos— es una herramienta de interés para la producción musical y el diseño sonoro, ya que permite expandir la paleta sonora más allá de los instrumentos acústicos existentes. Las técnicas usuales operan en el espacio latente de un único modelo generativo entrenado sobre múltiples instrumentos, lo que limita la fidelidad de cada timbre individual.

En este trabajo se propone un enfoque alternativo: entrenar autoencoders variacionales (β-VAE) especializados por instrumento a partir de un modelo base común, y generar timbres híbridos mediante la interpolación de los pesos de esos modelos.

El sistema se entrena sobre espectrogramas de magnitud obtenidos por STFT de cuatro instrumentos (piano, guitarra, voz y bajo) y se evalúa mediante Fréchet Audio Distance (FAD), similitud coseno sobre *embeddings* MERT, análisis del espacio latente con UMAP y error de reconstrucción.

Palabras claves: morphing tímbrico, autoencoder variacional, β-VAE, interpolación de pesos, síntesis de audio, Fréchet Audio Distance.

Índice general

1.. Introducción 1
- 1.1. Motivación 1
- 1.2. Antecedentes 1
- 1.3. Propuesta 1
- 1.4. Objetivos 1
- 1.5. Organización del trabajo 1

2.. Metodología 2
- 2.1. Datos y preprocesamiento 2
- 2.2. Arquitectura del modelo VAE 2
- 2.3. Estrategia de entrenamiento 2
- 2.4. Interpolación de pesos 2
- 2.5. Reconstrucción de audio 2
- 2.6. Métricas de evaluación 2
- 2.7. Aplicación interactiva 2

3.. Experimentación y resultados 3
- 3.1. Arquitectura del modelo y Experimentación β-VAE 3
- 3.2. Análisis del Espacio Latente 5
- 3.3. Interpolación 6
- 3.4. Barrido de dimensión del espacio latente 9
- 3.5. Variación de β 9
- 3.6. Análisis del espacio latente con UMAP 9
- 3.7. Interpolación entre pares de instrumentos 9
- 3.8. Audio morphing 9

4.. Conclusiones 10
- 4.1. Resumen de resultados 10
- 4.2. Contribuciones 10
- 4.3. Limitaciones 10
- 4.4. Trabajo futuro 10

1. INTRODUCCIÓN

1.1. Motivación

El timbre es el atributo perceptual que permite distinguir dos sonidos de igual altura y volumen producidos por fuentes distintas. La generación de timbres intermedios entre instrumentos conocidos, comúnmente denominada *morphing tímbrico*, resulta de particular interés tanto en la producción musical como en el diseño sonoro.

1.2. Antecedentes

Los autoencoders variacionales (VAE) fueron introducidos por Kingma y Welling [4] como un marco generativo que aprende representaciones latentes continuas mediante una distribución probabilística regularizada por la divergencia de Kullback-Leibler. Higgins et al. [3] propusieron el β-VAE, que pondera el término KL con un hiperparámetro β para controlar el balance entre calidad de reconstrucción y regularización del espacio latente.

En el modelado de sonido musical, Roche et al. [7] realizaron un estudio comparativo de distintas arquitecturas de autoencoders aplicadas a espectrogramas, mostrando que los modelos variacionales logran un buen compromiso entre reconstrucción y regularización del espacio latente. Caillon y Esling [1] demostraron con RAVE que los VAE pueden sintetizar audio de alta calidad en tiempo real. Riera, Eguía y Zabaljáuregui [6] exploraron la construcción de espacios de timbre mediante autoencoders dispersos, mostrando que las representaciones aprendidas capturan relaciones perceptuales entre timbres instrumentales.

Para la evaluación de audio generado se utiliza la Fréchet Audio Distance (FAD) [2], que cuantifica la distancia entre distribuciones de audio generado y de referencia a partir de *embeddings* neuronales.

1.3. Propuesta

1.4. Objetivos

1.5. Organización del trabajo

2. METODOLOGÍA

2.1. Datos y preprocesamiento

2.2. Arquitectura del modelo VAE

2.3. Estrategia de entrenamiento

2.4. Interpolación de pesos

2.5. Reconstrucción de audio

2.6. Métricas de evaluación

2.7. Aplicación interactiva

3. EXPERIMENTACIÓN Y RESULTADOS

3.1. Arquitectura del modelo y Experimentación β-VAE

Uno de los aspectos clave a definir en la arquitectura de los modelos es el tamaño del espacio latente. Como cabe esperar, a mayor dimensión del espacio latente menor es el error de reconstrucción; sin embargo, para el uso práctico de estos modelos resulta deseable mantener un tamaño acotado, de modo que las representaciones sean fáciles de manipular. Si pensamos en una implementación basada en perillas para modificar el espacio latente, contar con 4 perillas resulta coherente, mientras que tener 32 puede resultar poco intuitivo.

Con el objetivo de encontrar el tamaño ideal, experimentamos con dimensiones 2, 3, 4, 6 y 8, y graficamos el error de reconstrucción sobre el conjunto de validación para cada modelo (los modelos por instrumento y el modelo base). El propósito es verificar que el error disminuya a medida que la dimensión del espacio latente aumenta y, a la vez, evaluar si es posible evitar dimensiones tan grandes como 8 manteniendo una performance aceptable.

Fig. 3.1: Error de Reconstrucción (MSE) vs Dimensión de espacio latente, $\beta = 0$

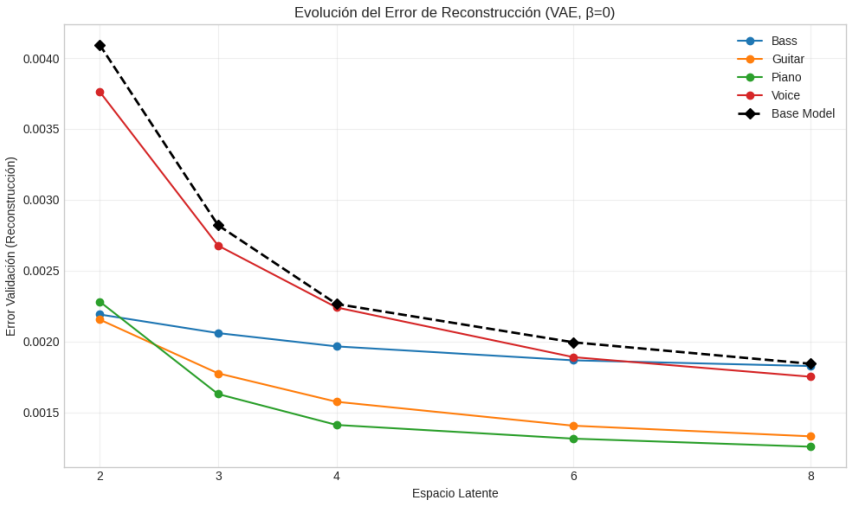

Analizando los resultados de las figuras 3.1 y 3.2 observamos que, con un espacio latente de dimensión 4, obtenemos una ganancia significativa respecto a las dimensiones 2 y 3, mientras que aumentar el tamaño a 6 u 8 no aporta una mejora relevante.

Nos interesa también verificar este comportamiento para la arquitectura β-VAE, donde esperamos observar un error de reconstrucción mayor en magnitud—ya que la *loss* de estos modelos incorpora también la divergencia KL—pero con la misma tendencia.

Fig. 3.2: Error de Reconstrucción promedio general

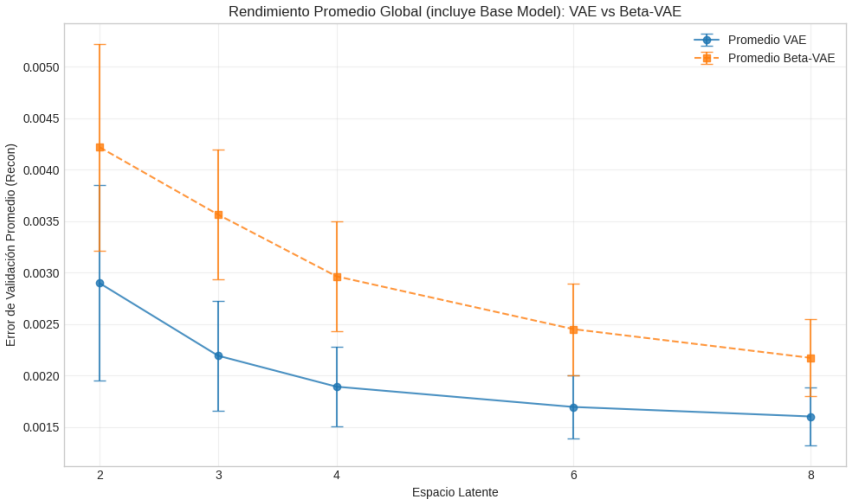

En efecto, lo observado para los modelos AE (con $\beta = 0$) se cumple también con β activado. Resta verificar el comportamiento de la divergencia KL en los modelos β-VAE para los distintos tamaños de espacio latente, presentado en la figura 3.3.

Fig. 3.3: Divergencia KL vs Dimensión de espacio latente, $\beta = 0{,}001$

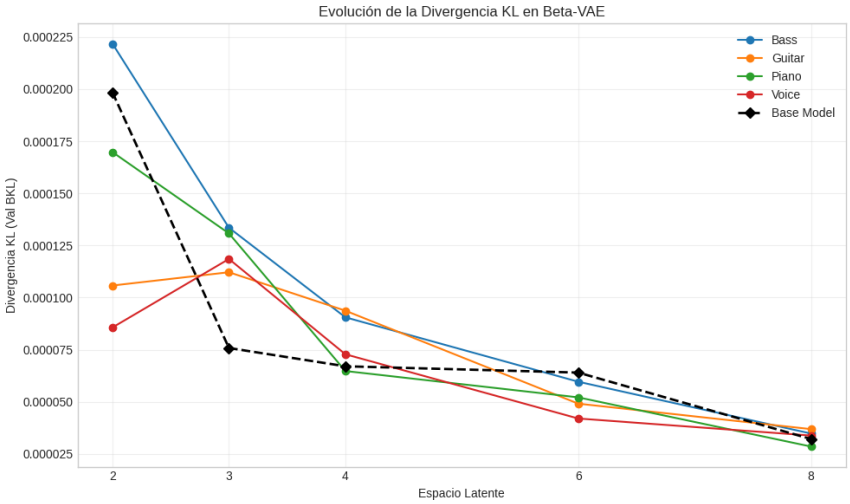

Efectivamente, el salto más significativo se encuentra entre las dimensiones 2 y 4, y a partir de allí la KL sigue disminuyendo pero con una ganancia relativa menor. En la figura 3.4 se presenta además el desglose del error de reconstrucción por instrumento, que confirma la misma tendencia. En base a estos resultados, adoptamos para el resto de los experimentos arquitecturas con espacio latente de dimensión 4.

Fig. 3.4: Desglose: Error de Reconstrucción (MSE) por modelo

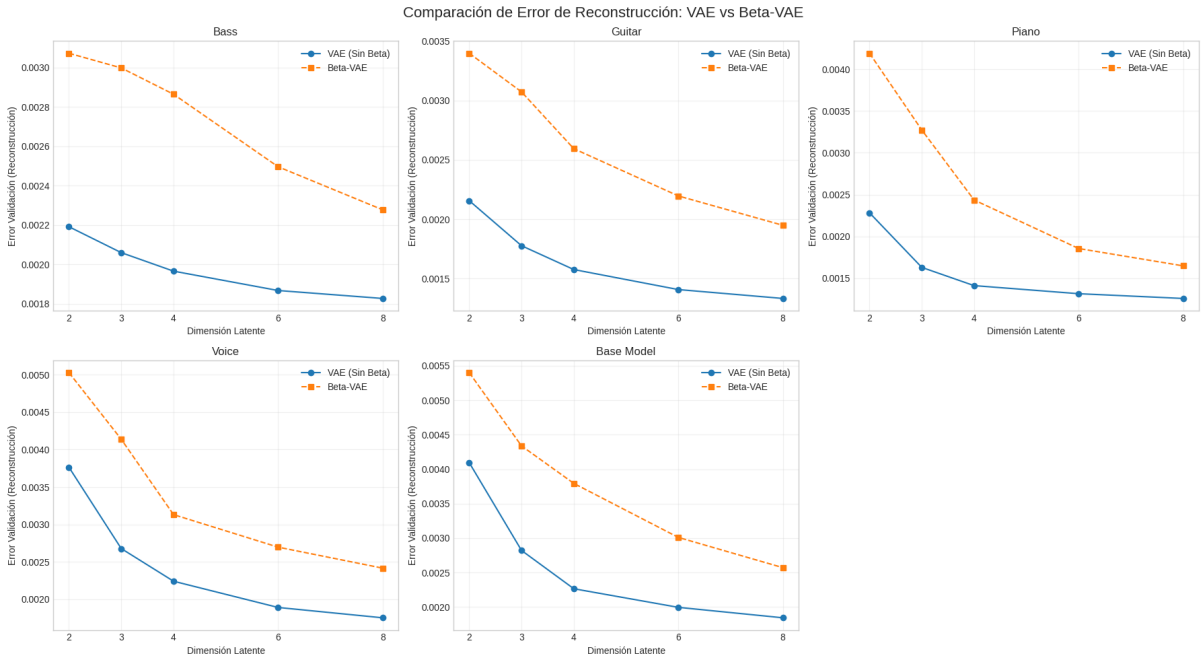

3.2. Análisis del Espacio Latente

Para analizar la organización del espacio latente del modelo base, proyectamos los *embeddings* a 2 dimensiones mediante UMAP, etiquetando cada muestra con el instrumento al que corresponde. Esto nos permite evaluar visualmente si los distintos instrumentos forman *clusters* diferenciados y comparar el comportamiento entre las configuraciones $\beta = 0$ y $\beta = 0{,}001$. Los resultados se presentan en la figura 3.5.

Fig. 3.5: Proyección a 2 dimensiones del espacio latente del modelo base utilizando UMAP.

(a) $\beta = 0{,}001$. *(b)* $\beta = 0$.

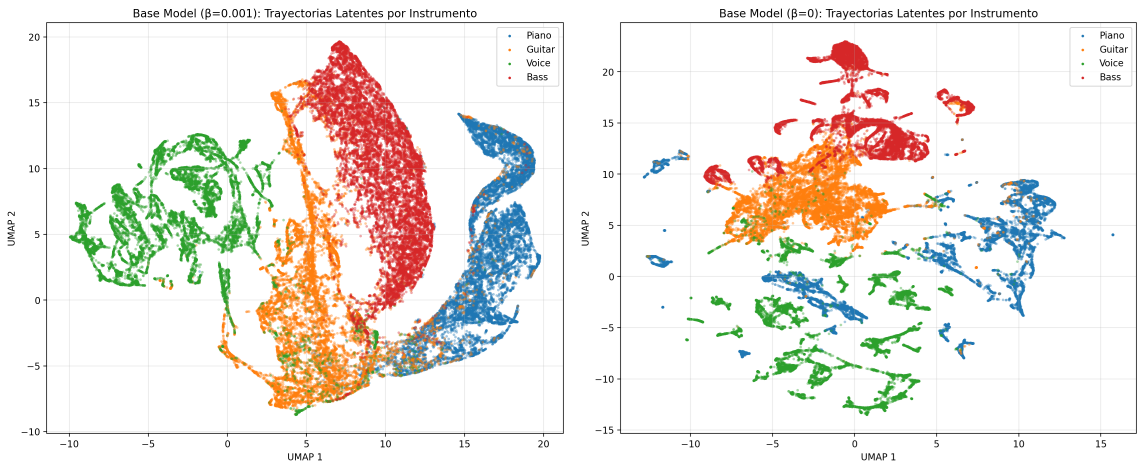

Para cuantificar la separación entre los *clusters* de cada instrumento computamos las

distancias entre sus centroides en la proyección UMAP, sintetizadas en la matriz de la figura 3.6.

Fig. 3.6: Matriz de separación entre *clusters* de instrumentos en la proyección UMAP.

(a) $\beta = 0{,}001$. (b) $\beta = 0$.

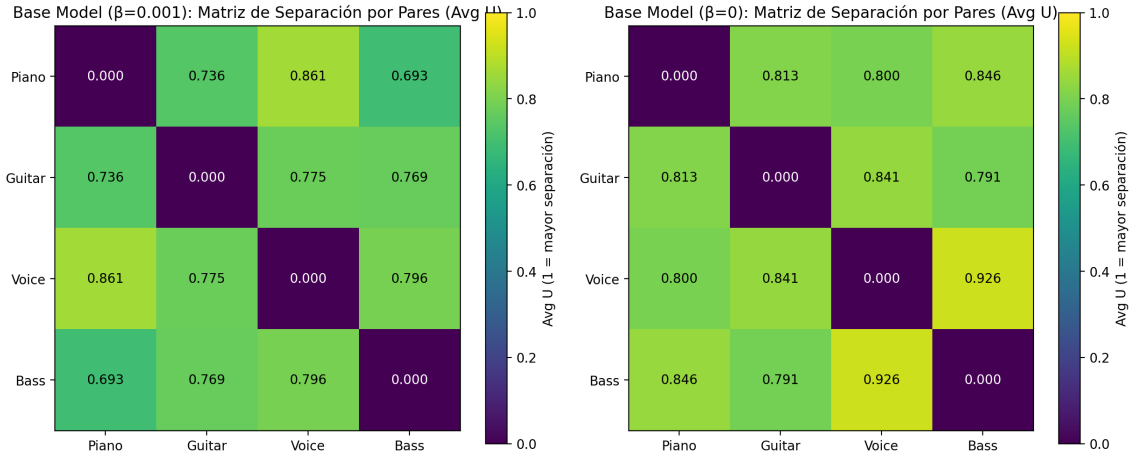

3.3. Interpolación

El primer experimento de interpolación tiene como objetivo verificar que la transición del parámetro α de 0 a 1 aproxima gradualmente las características del audio generado a las del instrumento de destino (Instrumento B). Para ello, se fijó el Instrumento B (en este caso, piano), se muestreó un vector latente aleatorio Z y se decodificó utilizando el modelo correspondiente a dicho instrumento, estableciendo así un audio de referencia. Posteriormente, para distintos valores intermedios de α, se interpolaron los pesos de los modelos A y B, se decodificó el mismo vector Z y se evaluó la similitud respecto al audio de referencia mediante dos métricas: similitud coseno sobre *embeddings* de MERT [5] y FAD (*Fréchet Audio Distance*) [2]. Trivialmente, cuando $\alpha = 1$ la interpolación coincide con el modelo del Instrumento B y la similitud alcanza su valor máximo. La hipótesis principal es que la similitud crecerá de forma monótona en función de α, evidenciando una transición acústica hacia el timbre del piano.

Este procedimiento se evaluó bajo cuatro configuraciones de entrenamiento, combinando el origen de los pesos (*checkpoint* común vs. desde *scratch*) con dos factores de regularización ($\beta = 0$ y $\beta = 0{,}001$). Esperamos observar un contraste significativo en la dinámica de interpolación entre los extremos. Partir de modelos con *checkpoint* compartido y $\beta > 0$ debería resultar en una curva más suave y predecible a medida que α aumenta, ya que la interpolación directa de pesos es más efectiva cuando los modelos habitan el mismo entorno en el espacio de parámetros. Por el contrario, al interpolar modelos entrenados desde *scratch* y sin regularización, es probable que los valores intermedios de α generen representaciones ruidosas, impidiendo un crecimiento gradual de la similitud y resultando en un salto abrupto únicamente para valores de α cercanos a 1.

Para garantizar la robustez de los resultados, este proceso se repitió utilizando 10 vectores latentes aleatorios diferentes. En las figuras 3.7, 3.8, 3.9 y 3.10 se reporta el promedio de las métricas de similitud, junto con su desviación estándar, para cada valor

de α.

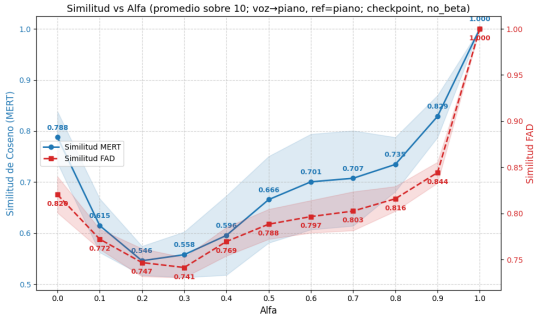

Fig. 3.7: Similitud en función de α, entrenado desde *checkpoint*, $\beta = 0$

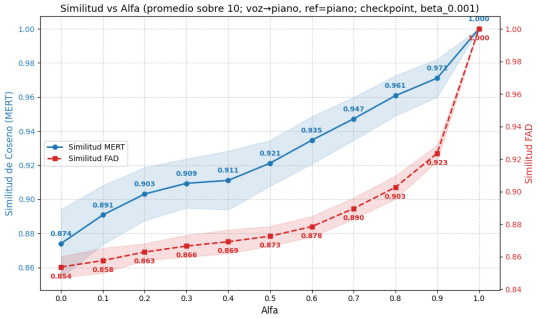

Fig. 3.8: Similitud en función de α, entrenado desde *checkpoint*, $\beta = 0{,}001$

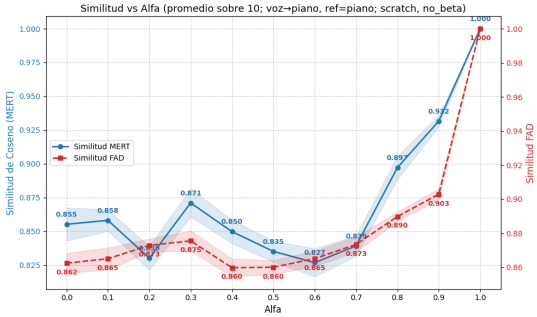

Fig. 3.9: Similitud en función de α, entrenado desde *scratch*, $\beta = 0$

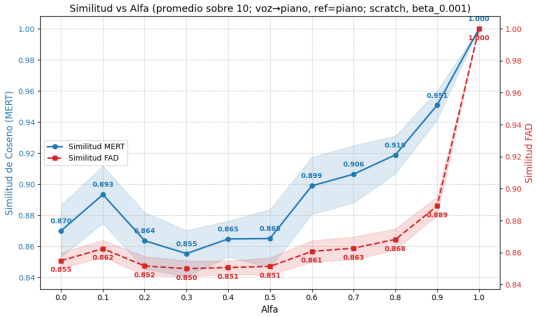

Fig. 3.10: Similitud en función de α, entrenado desde *scratch*, $\beta = 0{,}001$

En la figura 3.8 se observa, en ambas métricas, un crecimiento suave y consistente al aumentar α, mientras que en el caso de modelos entrenados desde *scratch* y sin regularización (figura 3.9) no se aprecia una mejora entre $\alpha = 0$ y $\alpha = 0{,}7$. Recién para $\alpha \in [0{,}8, 1{,}0]$ se observa una subida pronunciada, dado que en ese rango la interpolación está dominada por los pesos del modelo del instrumento B.

Esta observación confirma nuestra hipótesis: interpolar modelos entrenados desde *scratch* y sin regularización ($\beta = 0$) conduce a peores resultados de interpolación.

Con esto verificamos que acercar α a un extremo aproxima efectivamente el sonido al instrumento correspondiente. Resta verificar también que la interpolación se aleja del instrumento A y que no se aproxima, en promedio, a otros instrumentos no involucrados.

Para ello proponemos un experimento similar en el que se mide la similitud contra un audio de referencia del instrumento A, otro del instrumento B y un audio de un instrumento *testigo* (distinto de A y B). A medida que crece α esperamos que la similitud al instrumento B aumente y la del instrumento A disminuya, mientras que la del instrumento testigo se mantenga aproximadamente constante. Esperamos también que las curvas de similitud de los instrumentos A y B se crucen aproximadamente en $\alpha = 0{,}5$.

Comparamos las cuatro configuraciones de modelos resultantes de combinar el origen (*checkpoint* y *scratch*) con los valores $\beta = 0$ y $\beta = 0{,}001$. Usamos piano como instrumento A, guitarra como instrumento B y voz como instrumento testigo. Los resultados se presentan en la figura 3.11.

Fig. 3.11: Transición de piano a guitarra: comparación entre origen de los pesos (*checkpoint* vs. *scratch*) y valores de β. La voz actúa como instrumento testigo.

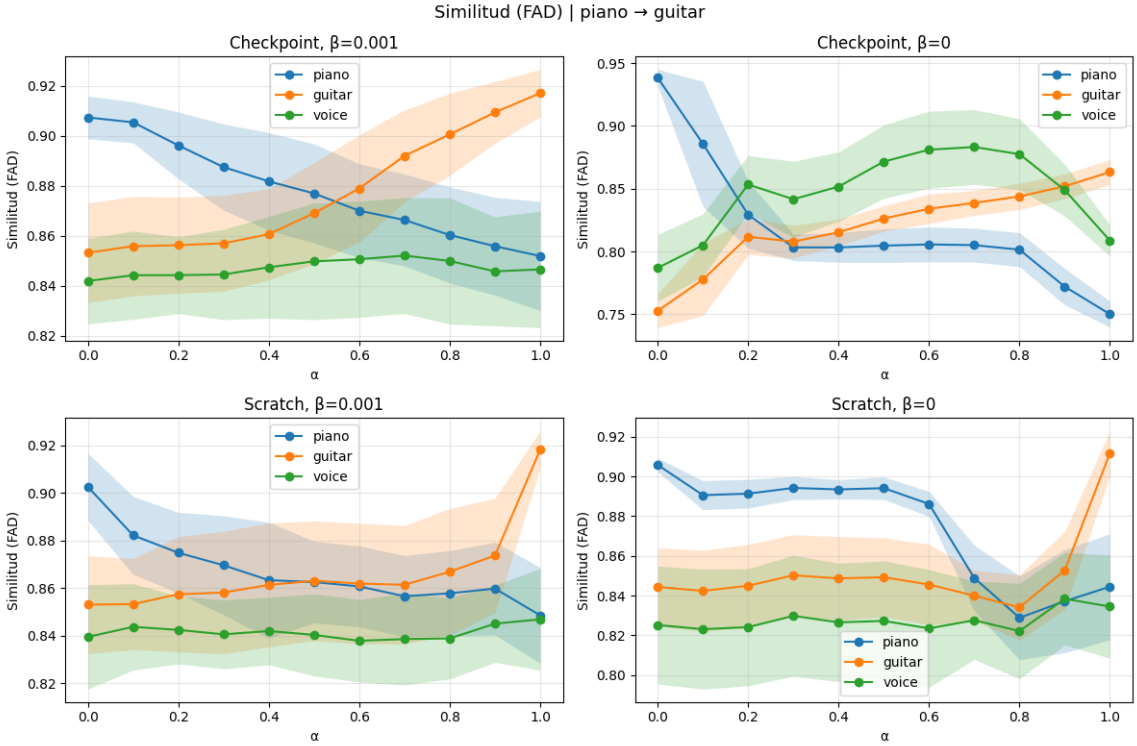

Como esperábamos, la configuración que mejor se comporta es la de modelos entrenados desde *checkpoint* con $\beta = 0{,}001$: se observa que la similitud al instrumento A (piano) decrece consistentemente al mismo tiempo que la del instrumento B (guitarra) crece, cruzándose alrededor de $\alpha = 0{,}5$. La similitud de la voz, por su parte, se mantiene aproximadamente constante.

En cambio, para los modelos entrenados desde *scratch* el comportamiento es menos predecible: con $\beta = 0{,}001$ se observa una leve transferencia tímbrica, aunque poco consistente, ya que para valores intermedios de α apenas hay variación; con $\beta = 0$ directamente no hay transferencia y la similitud al instrumento B recién aumenta a partir de $\alpha = 0{,}8$.

El caso de *checkpoint* con $\beta = 0$ sí logra la transferencia tímbrica buscada, aunque de manera más abrupta: se observa una caída pronunciada de la similitud al instrumento A en los primeros valores de α. Además, en esta configuración el instrumento testigo presenta un comportamiento más errático.

Con este experimento confirmamos que la configuración más adecuada para la interpolación es la de modelos entrenados desde *checkpoint* con $\beta > 0$, en particular $\beta = 0{,}001$.

3.4. Barrido de dimensión del espacio latente

3.5. Variación de β

3.6. Análisis del espacio latente con UMAP

3.7. Interpolación entre pares de instrumentos

3.8. Audio morphing

4. CONCLUSIONES

4.1. Resumen de resultados

4.2. Contribuciones

4.3. Limitaciones

4.4. Trabajo futuro

Bibliografía

[1] Caillon, A., and Esling, P. Rave: A variational autoencoder for fast and high-quality neural audio synthesis. *arXiv preprint arXiv:2111.05011* (2021).

[2] Gui, A., Gamper, H., Braun, S., and Emmanouilidou, D. Adapting frechet audio distance for generative music evaluation, 2024.

[3] Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., Mohamed, S., and Lerchner, A. beta-vae: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations (ICLR)* (2017).

[4] Kingma, D. P., and Welling, M. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114* (2013).

[5] Li, Y., Yuan, R., Zhang, G., Ma, Y., Chen, X., Yin, H., Xiao, C., Lin, C., Ragni, A., Benetos, E., Gyenge, N., Dannenberg, R., Liu, R., Chen, W., Xia, G., Shi, Y., Huang, W., Wang, Z., Guo, Y., and Fu, J. Mert: Acoustic music understanding model with large-scale self-supervised training, 2023.

[6] Riera, P. E., Eguía, M. C., and Zabaljáuregui, M. Timbre spaces with sparse autoencoders. In *16th Brazilian Symposium on Computer Music (SBCM)* (2017).

[7] Roche, F., Hueber, T., Limier, S., and Girin, L. Autoencoders for music sound modeling: a comparison of linear, shallow, deep, recurrent and variational models, 2019.